LH_CD_BRUNADERNER

September 2, 2025

Desafio

Você foi alocado em um time da Indicium contratado por um estúdio de Hollywood chamado PProductions, e agora deve fazer uma análise em cima de um banco de dados cinematográfico para orientar qual tipo de filme deve ser o próximo a ser desenvolvido. Lembre-se que há muito dinheiro envolvido, então a análise deve ser muito detalhada e levar em consideração o máximo de fatores possíveis (a introdução de dados externos é permitida - e encorajada).

Dados Externos - Decidi pegar variaveis externas utilizando uma API da TMDB, coletei informações sobre a linguagem utilizada, orçamento dos filmes e keywords. - Também peguei um banco de dados sobre o Oscar pra poder trazer na base de dados a relação de se um ator ou diretor possuia oscar antes de fazer o filme em questão, se isso influenciava.

Separação - os estão dispostos da seguinte forma: - Carregando Dados tem o merge de todas as variaveis e preparação de um mesmo dataset. - Limpeza e Tratamento dos dados tem toda a preparação dos dados para o EDA - EDA: Avaliação visual para compreensão da disposição dos dados - variável alvo: análises acerca do IMDb - exploração da estrutura dos dados: a visualização de como os dados estão dispostos em relação ao ano, aos generos, a classificação etc. - Hipóteses traz os testes em relação ao que foi visto no EDA e também ao que poderia se supor sobre a base de dados. - Perguntas são as 3 perguntas do desafio: - Qual filme você recomendaria para uma pessoa que você não conhece? - Quais são os principais fatores que estão relacionados com alta expectativa de faturamento de um filme? - Quais insights podem ser tirados com a coluna Overview? É possível inferir o gênero do filme a partir dessa coluna? - Explicações está os modelos preditivos do IMDb - Suposição de Filme com características específicas é o teste do modelo que foi treinado com um dado fora do dataset. - Adendo: nesse tópico eu trago uma rutura temporal devido a ter um desequilíbrio na base, em que antes de 1990 os dados se comportam de uma forma e posterior de outra. Ali eu coloco pesos de tempo, e dummies tentando minimizar esse viés e também tentando alcançar um bom modelo preditivo.

1 Carregando os dados

[ ]:
```
import re

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

from scipy.stats import pearsonr, f_oneway
```

```
from scipy.sparse import hstack, csr_matrix

from sklearn.model_selection import train_test_split, RandomizedSearchCV
from sklearn.metrics import (
    r2_score, mean_squared_error, mean_absolute_error,
    f1_score, classification_report
)
from sklearn.ensemble import RandomForestRegressor, RandomForestClassifier
from sklearn.linear_model import LinearRegression, Ridge, LogisticRegression
from sklearn.feature_extraction.text import TfidfVectorizer, CountVectorizer
from sklearn.decomposition import TruncatedSVD
from sklearn.multiclass import OneVsRestClassifier

from xgboost import XGBRegressor
```

[ ]:
```
tabela = pd.read_csv('desafio_indicium_imdb.csv')
tabela.head()
```

[ ]:
```
   Unnamed: 0                                  Series_Title Released_Year
0           1                                The Godfather          1972  \
1           2                              The Dark Knight          2008
2           3                     The Godfather: Part II          1974
3           4                                  12 Angry Men          1957
4           5  The Lord of the Rings: The Return of the King          2003

  Certificate  Runtime                     Genre  IMDB_Rating
0           A  175 min              Crime, Drama          9.2  \
1          UA  152 min      Action, Crime, Drama          9.0
2           A  202 min              Crime, Drama          9.0
3           U   96 min              Crime, Drama          9.0
4           U  201 min  Action, Adventure, Drama          8.9

                                            Overview  Meta_score
0  An organized crime dynasty's aging patriarch t…       100.0  \
1  When the menace known as the Joker wreaks havo…        84.0
2  The early life and career of Vito Corleone in …        90.0
3  A jury holdout attempts to prevent a miscarria…        96.0
4  Gandalf and Aragorn lead the World of Men agai…        94.0

              Director           Star1            Star2          Star3
0  Francis Ford Coppola   Marlon Brando        Al Pacino     James Caan  \
1     Christopher Nolan  Christian Bale     Heath Ledger  Aaron Eckhart
2  Francis Ford Coppola       Al Pacino   Robert De Niro  Robert Duvall
3          Sidney Lumet     Henry Fonda      Lee J. Cobb  Martin Balsam
4         Peter Jackson     Elijah Wood  Viggo Mortensen   Ian McKellen

           Star4  No_of_Votes        Gross
```

```
0   Diane Keaton      1620367  134,966,411
1  Michael Caine      2303232  534,858,444
2   Diane Keaton      1129952   57,300,000
3   John Fiedler       689845    4,360,000
4  Orlando Bloom      1642758  377,845,905
```

[ ]:
```
oscars = pd.read_csv('the_oscar_award.csv')
oscars.head()
```

[ ]:
```
   year_film  year_ceremony  ceremony category            canon_category
0       1927           1928         1    ACTOR    ACTOR IN A LEADING ROLE  \
1       1927           1928         1    ACTOR    ACTOR IN A LEADING ROLE
2       1927           1928         1    ACTOR    ACTOR IN A LEADING ROLE
3       1927           1928         1    ACTOR    ACTOR IN A LEADING ROLE
4       1927           1928         1  ACTRESS  ACTRESS IN A LEADING ROLE

                 name                    film  winner
0  Richard Barthelmess              The Noose   False
1  Richard Barthelmess  The Patent Leather Kid   False
2       Emil Jannings       The Last Command    True
3       Emil Jannings   The Way of All Flesh    True
4      Louise Dresser         A Ship Comes In   False
```

Essa base de dados do Oscar eu consegui no Kaggle, neste link: https://www.kaggle.com/datasets/unanimad/the-oscar-award

[ ]:
```
complementares = pd.read_csv('complementares.csv')
complementares.head()
```

[ ]:
```
   row_index                                    query_title  query_year
0          0                                The Godfather      1972.0  \
1          1                              The Dark Knight      2008.0
2          2                        The Godfather: Part II      1974.0
3          3                                  12 Angry Men      1957.0
4          4  The Lord of the Rings: The Return of the King      2003.0

   tmdb_id                                matched_title
0    238.0                                The Godfather  \
1    155.0                              The Dark Knight
2    240.0                        The Godfather Part II
3    389.0                                  12 Angry Men
4    122.0  The Lord of the Rings: The Return of the King

                            original_title release_date   budget_usd
0                            The Godfather   1972-03-14    6000000.0  \
1                          The Dark Knight   2008-07-16  185000000.0
2                  The Godfather Part II   1974-12-20   13000000.0
```

```
3                                 12 Angry Men   1957-04-10     397751.0
4  The Lord of the Rings: The Return of the King   2003-12-17   94000000.0

    revenue_usd    profit_usd  …  vote_count  popularity
0  2.450664e+08  2.390664e+08  …     21771.0     27.4415  \
1  1.004558e+09  8.195584e+08  …     34300.0     31.0804
2  1.026000e+08  8.960000e+07  …     13143.0     15.7352
3  4.360000e+06  3.962249e+06  …      9355.0     14.3753
4  1.118889e+09  1.024889e+09  …     25395.0     23.9887

                         genres
0                  Drama, Crime  \
1  Drama, Action, Crime, Thriller
2                  Drama, Crime
3                         Drama
4     Adventure, Fantasy, Action

                                             keywords    status
0  based on novel or book, loss of loved one, lov…  Released  \
1  sadism, chaos, secret identity, crime fighter,…  Released
2  new year's eve, new york city, based on novel …  Released
3  death penalty, anonymity, court case, court, j…  Released
4  army, based on novel or book, elves, dwarf, ma…  Released

  original_language    imdb_id
0                en  tt0068646  \
1                en  tt0468569
2                en  tt0071562
3                en  tt0050083
4                en  tt0167260

                                       homepage found _error
0                   http://www.thegodfather.com/  True    NaN
1  https://www.warnerbros.com/movies/dark-knight/  True    NaN
2                                             NaN  True    NaN
3                                             NaN  True    NaN
4                  http://www.lordoftherings.net  True    NaN

[5 rows x 23 columns]
```

Esse conjunto de dados complementares peguei no site tmdb, pela API deles

[ ]:
```
# criando uma lista pra salvar os nomes das classes
classes = []

#vau olhar cada valor da coluna canon_category
for cat in oscars["canon_category"]:
```

```
    # se for vazio coloca nada
    if pd.isna(cat):
        classes.append(None)
    else:
        #deixa o texto em maiusculo pra comparar
        c = str(cat).upper()
        # se tiver escrito actor ou actress eu falo q é ator
        if "ACTOR" in c or "ACTRESS" in c:
            classes.append("ATOR")
        # se tiver escrito direct eu falo q é diretor
        elif "DIRECT" in c:
            classes.append("DIRETOR")
        # se nao for nada disso eu coloco filme
        else:
            classes.append("FILME")

# criando uma coluna nova com a lista q eu fiz
oscars["category_3class"] = classes

#exibri
print(oscars["category_3class"].value_counts(dropna=False))
```

```
category_3class
FILME      8091
ATOR       1855
DIRETOR    1164
Name: count, dtype: int64
```

[ ]:
```
#Aqui eu estou fazendo alguns tratamentos nas duas tabelas para que possa dar␣
 ↪merge, visto que estão com nome diferente de variavel.
##Primeiro vou transformar em numerico oq não for vira NaN, mas fica type float
tabela['Released_Year'] = pd.to_numeric(tabela['Released_Year'],␣
 ↪errors='coerce')
##O valor que está nulo em Released_Year é do filme Apollo 13 de Tom Hanks, que␣
 ↪foilançado em 1995, sendo assim o irei imputar.
tabela['Released_Year'].fillna(1995, inplace=True)
#Agora força ele a virar INT64, já q não tem mais NaN
tabela['Released_Year'] = tabela['Released_Year'].astype('int64')


#Agora iremos padronizar a escrita para poder dar "merge"
##tabela
tabela['Series_Title'] = (tabela['Series_Title'].astype(str).str.lower().str.
 ↪strip().str.replace(r'\s+', ' ', regex=True))
tabela['Director'] = (tabela['Director'].astype(str).str.lower().str.strip().
 ↪str.replace(r'\s+', ' ', regex=True))
```

```
tabela['Star1'] = (tabela['Star1'].astype(str).str.lower().str.strip().str.
 ↪replace(r'\s+', ' ', regex=True))
tabela['Star2'] = (tabela['Star2'].astype(str).str.lower().str.strip().str.
 ↪replace(r'\s+', ' ', regex=True))
tabela['Star3'] = (tabela['Star3'].astype(str).str.lower().str.strip().str.
 ↪replace(r'\s+', ' ', regex=True))
tabela['Star4'] = (tabela['Star4'].astype(str).str.lower().str.strip().str.
 ↪replace(r'\s+', ' ', regex=True))

##oscars
oscars['film'] = (oscars['film'].astype(str).str.lower().str.strip().str.
 ↪replace(r'\s+', ' ', regex=True))
oscars['year_film'] = oscars['year_film'].astype('Int64')
oscars['name'] = (oscars['name'].astype(str).str.lower().str.strip().str.
 ↪replace(r'\s+', ' ', regex=True))
oscars['winner'] = oscars['winner'].fillna(False).astype(bool)

##complementares
complementares['query_title'] = (complementares['query_title'].astype(str).str.
 ↪lower().str.strip().str.replace(r'\s+', ' ', regex=True))
complementares['query_year'] = complementares['query_year'].astype('Int64')
complementares['budget_usd'] = complementares['budget_usd'].astype('float')
complementares['keywords'] = (complementares['keywords'].astype(str).str.
 ↪lower().str.strip().str.replace(r'\s+', ' ', regex=True))
complementares['original_language'] = (complementares['original_language'].
 ↪astype(str).str.lower().str.strip().str.replace(r'\s+', ' ', regex=True))

# classificar em 3 classes oscars
def map_to_3classes(category):
    if pd.isna(category):
        return None
    c = str(category).upper()
    if "ACTOR" in c or "ACTRESS" in c:
        return "ACTOR"
    if "DIRECT" in c:
        return "DIRECTOR"
    return "FILM"

oscars['canon_category'] = oscars['canon_category'].map(map_to_3classes)

#função auxiliar para classificar se os atores e diretores já tinham oscar␣
 ↪antes do filme ser lançado
def ganhou_oscar_antes(nome, ano, categoria):
    dados = oscars[(oscars['name'] == nome) &
                   (oscars['canon_category'] == categoria) &
                   (oscars['winner']) &
```

```
                    (oscars['year_film'] <= ano)]
    return int(not dados.empty)

tabela['Star1_OscarActor_Winner'] = tabela.apply(lambda row:␣
 ↪ganhou_oscar_antes(row['Star1'], row['Released_Year'], 'ACTOR'), axis=1)
tabela['Star2_OscarActor_Winner'] = tabela.apply(lambda row:␣
 ↪ganhou_oscar_antes(row['Star2'], row['Released_Year'], 'ACTOR'), axis=1)
tabela['Star3_OscarActor_Winner'] = tabela.apply(lambda row:␣
 ↪ganhou_oscar_antes(row['Star3'], row['Released_Year'], 'ACTOR'), axis=1)
tabela['Star4_OscarActor_Winner'] = tabela.apply(lambda row:␣
 ↪ganhou_oscar_antes(row['Star4'], row['Released_Year'], 'ACTOR'), axis=1)

tabela['Director_OscarDirector_Winner'] = tabela.apply(lambda row:␣
 ↪ganhou_oscar_antes(row['Director'], row['Released_Year'], 'DIRECTOR'),␣
 ↪axis=1)

#oscars do filme
def filme_oscar_info(titulo):
    dados = oscars[
        (oscars['film'] == titulo) &
        (oscars['winner'])
    ]
    return int(not dados.empty), len(dados)

#aplicar em toda a tabela
tabela[['Filme_OscarWinner','Filme_OscarCount']] = tabela['Series_Title'].apply(
    lambda t: pd.Series(filme_oscar_info(t))
)

#remover a coluna "Unnamed: 0"
if 'Unnamed: 0' in tabela.columns:
    tabela = tabela.drop(columns=['Unnamed: 0'])

tabela = tabela.merge(complementares[['query_title', 'query_year',␣
 ↪'budget_usd', 'original_language', 'keywords']],
    left_on=['Series_Title', 'Released_Year'],
    right_on=['query_title', 'query_year'],
    how='left'
).drop(columns=['query_title', 'query_year']) \
 .rename(columns={
     'budget_usd': 'Budget_USD',
     'original_language': 'Original_Language',
     'keywords': 'Keywords'
 })

tabela.head()
```

[ ]:

```
                                  Series_Title  Released_Year Certificate
0                                 the godfather           1972           A  \
1                              the dark knight            2008          UA
2                         the godfather: part ii           1974           A
3                                   12 angry men           1957           U
4  the lord of the rings: the return of the king           2003           U

   Runtime                     Genre  IMDB_Rating
0  175 min              Crime, Drama          9.2  \
1  152 min      Action, Crime, Drama          9.0
2  202 min              Crime, Drama          9.0
3   96 min              Crime, Drama          9.0
4  201 min  Action, Adventure, Drama          8.9

                                            Overview  Meta_score
0  An organized crime dynasty's aging patriarch t…       100.0  \
1  When the menace known as the Joker wreaks havo…        84.0
2  The early life and career of Vito Corleone in …        90.0
3  A jury holdout attempts to prevent a miscarria…        96.0
4  Gandalf and Aragorn lead the World of Men agai…        94.0

               Director           Star1  … Star1_OscarActor_Winner
0  francis ford coppola   marlon brando  …                       1  \
1     christopher nolan  christian bale  …                       0
2  francis ford coppola       al pacino  …                       0
3          sidney lumet     henry fonda  …                       0
4         peter jackson     elijah wood  …                       0

  Star2_OscarActor_Winner Star3_OscarActor_Winner  Star4_OscarActor_Winner
0                       0                       0                       0  \
1                       1                       0                       1
2                       1                       0                       0
3                       0                       0                       0
4                       0                       0                       0

  Director_OscarDirector_Winner  Filme_OscarWinner  Filme_OscarCount
0                             0                  1                 3  \
1                             0                  1                 2
2                             1                  0                 0
3                             0                  0                 0
4                             1                  1                11

    Budget_USD  Original_Language
0    6000000.0                 en  \
1  185000000.0                 en
2   13000000.0                 en
3     397751.0                 en
```

```
4   94000000.0                 en

                                                Keywords
0  based on novel or book, loss of loved one, lov…
1  sadism, chaos, secret identity, crime fighter,…
2  new year's eve, new york city, based on novel …
3  death penalty, anonymity, court case, court, j…
4  army, based on novel or book, elves, dwarf, ma…

[5 rows x 25 columns]
```

2 Limpeza e Tratamento dos dados

2.1 Identificando duplicados

[ ]:
```
#Verificando se há valores duplicados
tabela.duplicated().sum()
```

[ ]:
```
0
```

Ótimo, o 0 representa que não temos duplicatas.

2.2 Alterando tipo de variável

[ ]:
```
tabela.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 999 entries, 0 to 998
Data columns (total 25 columns):
 #   Column                      Non-Null Count  Dtype
---  ------                      --------------  -----
 0   Series_Title                999 non-null    object
 1   Released_Year               999 non-null    int64
 2   Certificate                 898 non-null    object
 3   Runtime                     999 non-null    object
 4   Genre                       999 non-null    object
 5   IMDB_Rating                 999 non-null    float64
 6   Overview                    999 non-null    object
 7   Meta_score                  842 non-null    float64
 8   Director                    999 non-null    object
 9   Star1                       999 non-null    object
 10  Star2                       999 non-null    object
 11  Star3                       999 non-null    object
 12  Star4                       999 non-null    object
 13  No_of_Votes                 999 non-null    int64
 14  Gross                       830 non-null    object
 15  Star1_OscarActor_Winner     999 non-null    int64
```

```
 16  Star2_OscarActor_Winner         999 non-null    int64
 17  Star3_OscarActor_Winner         999 non-null    int64
 18  Star4_OscarActor_Winner         999 non-null    int64
 19  Director_OscarDirector_Winner   999 non-null    int64
 20  Filme_OscarWinner               999 non-null    int64
 21  Filme_OscarCount                999 non-null    int64
 22  Budget_USD                      997 non-null    float64
 23  Original_Language               998 non-null    object
 24  Keywords                        998 non-null    object
dtypes: float64(3), int64(9), object(13)
memory usage: 195.2+ KB
```

[ ]:
```
#Alterar o tipo das variaveis:

#Variável Realesed_Year
##Essa está em int e iremos transformar em datetime, nessa transformação␣
 ↪assume-se 1° de janeiro
tabela['Released_Year'] = pd.to_datetime(tabela['Released_Year'], format='%Y',␣
 ↪errors='coerce')

#Variável Runtime
##Essa variável tem o complemento 'min' no final, então tiraremos esse e iremos␣
 ↪transformar em número inteiro
tabela['Runtime'] = (tabela['Runtime'].str.replace('min', '', regex=False).
 ↪astype(float))

#Variável Grossf5
tabela['Gross'] = (tabela['Gross'].replace('[\$,]', '', regex=True))
#Converte para número e coloca NaN no que não for número
tabela['Gross'] = pd.to_numeric(tabela['Gross'], errors='coerce')

tabela['Budget_USD'] = (tabela['Budget_USD'].replace('[\$,]', '', regex=True))
tabela['Budget_USD']  = pd.to_numeric(tabela['Budget_USD'],  errors='coerce')

#Variável Genre
##Essa variável está com vários gêneros em uma mesma célula, sendo assim,␣
 ↪iremos fazer get dummies com one hot enconding pra poder avaliar esses␣
 ↪generos separadamente
generos_dummies = tabela['Genre'].str.get_dummies(sep=', ')
tabela = pd.concat([tabela, generos_dummies], axis=1)

# Variável original_language
## Essa variável está um idioma por flme, então usamos get_dummies
idiomas_dummies = pd.get_dummies(tabela['Original_Language'], prefix='lang',␣
 ↪drop_first=True)
tabela = pd.concat([tabela, idiomas_dummies], axis=1)
```

```
genero_cols = generos_dummies.columns.tolist()
idioma_cols = idiomas_dummies.columns.tolist()
```

[ ]:
```
#achar filmes com budget nulo ou zero
problemas = tabela[(tabela["Budget_USD"].isna()) | (tabela["Budget_USD"] == 0)]

print("filmes com budget zerado ou nulo:", len(problemas))
print(problemas[["Series_Title","Released_Year","Gross","Budget_USD"]].head(20))
```

```
filmes com budget zerado ou nulo: 155
                          Series_Title Released_Year      Gross  Budget_USD
19                      soorarai pottru    2020-01-01        NaN         0.0
29                              seppuku    1962-01-01        NaN         0.0
54                         vikram vedha    2017-01-01        NaN         0.0
55                       kimi no na wa.    2016-01-01  5017246.0         0.0
75                                anand    1971-01-01        NaN         0.0
84                              tumbbad    2018-01-01        NaN         0.0
88              jodaeiye nader az simin    2011-01-01  7098492.0         0.0
90                 miracle in cell no.7    2019-01-01        NaN         0.0
91                       babam ve oglum    2005-01-01        NaN         0.0
104                        idi i smotri    1985-01-01        NaN         0.0
120                               ikiru    1952-01-01    55240.0         0.0
124  m - eine stadt sucht einen mörder    1931-01-01    28877.0         0.0
128           uri: the surgical strike    2018-01-01  4186168.0         0.0
129                  k.g.f: chapter 1    2018-01-01        NaN         0.0
132                            talvar    2015-01-01   342370.0         0.0
134                             klaus    2019-01-01        NaN         0.0
137                       mandariinid    2013-01-01   144501.0         0.0
141                  paan singh tomar    2012-01-01    39567.0         0.0
162                            eskiya    1996-01-01        NaN         0.0
165                  andaz apna apna    1994-01-01        NaN         0.0
```

[ ]:
```
#Aqui to alterando o Certificate pra maiuscula
tabela['Certificate'] = tabela['Certificate'].astype(str).str.strip().str.
 ↪upper()

#Trocando "U/A" por "UA"
tabela['Certificate'] = tabela['Certificate'].str.replace("U/A", "UA")

#Voltando valores "NAN" para NaN
tabela.loc[tabela['Certificate'] == "NAN", 'Certificate'] = pd.NA

print(tabela['Certificate'].unique())
print(tabela['Certificate'].value_counts(dropna=False))
```

```
['A' 'UA' 'U' 'PG-13' 'R' <NA> 'PG' 'G' 'PASSED' 'TV-14' '16' 'TV-MA'
 'UNRATED' 'GP' 'APPROVED' 'TV-PG']
```

```
Certificate
U           234
A           196
UA          176
R           146
<NA>        101
PG-13        43
PG           37
PASSED       34
G            12
APPROVED     11
TV-PG         3
GP            2
TV-14         1
16            1
TV-MA         1
UNRATED       1
Name: count, dtype: int64
```

[ ]:
```
#Vamos verificar a distribuição dos valores numéricos
tabela.describe()
```

[ ]:
```
                      Released_Year     Runtime  IMDB_Rating  Meta_score  \
count                           999  999.000000   999.000000  842.000000
mean   1991-03-21 19:46:18.378378368  122.871872     7.947948   77.969121
min              1920-01-01 00:00:00   45.000000     7.600000   28.000000
25%              1976-01-01 00:00:00  103.000000     7.700000   70.000000
50%              1999-01-01 00:00:00  119.000000     7.900000   79.000000
75%              2009-01-01 00:00:00  137.000000     8.100000   87.000000
max              2020-01-01 00:00:00  321.000000     9.200000  100.000000
std                              NaN   28.101227     0.272290   12.383257

        No_of_Votes         Gross  Star1_OscarActor_Winner
count  9.990000e+02  8.300000e+02               999.000000  \
mean   2.716214e+05  6.808257e+07                 0.163163
min    2.508800e+04  1.305000e+03                 0.000000
25%    5.547150e+04  3.245338e+06                 0.000000
50%    1.383560e+05  2.345744e+07                 0.000000
75%    3.731675e+05  8.087634e+07                 0.000000
max    2.303232e+06  9.366622e+08                 1.000000
std    3.209126e+05  1.098076e+08                 0.369700

       Star2_OscarActor_Winner  Star3_OscarActor_Winner
count               999.000000               999.000000  \
mean                  0.126126                 0.074074
min                   0.000000                 0.000000
25%                   0.000000                 0.000000
```

```
50%                    0.000000                 0.000000
75%                    0.000000                 0.000000
max                    1.000000                 1.000000
std                    0.332158                 0.262023

       Star4_OscarActor_Winner  …      Horror       Music     Musical
count               999.000000  …  999.000000  999.000000  999.000000  \
mean                  0.048048  …    0.032032    0.035035    0.017017
min                   0.000000  …    0.000000    0.000000    0.000000
25%                   0.000000  …    0.000000    0.000000    0.000000
50%                   0.000000  …    0.000000    0.000000    0.000000
75%                   0.000000  …    0.000000    0.000000    0.000000
max                   1.000000  …    1.000000    1.000000    1.000000
std                   0.213975  …    0.176173    0.183960    0.129399

           Mystery     Romance      Sci-Fi       Sport    Thriller         War
count  999.000000  999.000000  999.000000  999.000000  999.000000  999.000000  \
mean     0.099099    0.125125    0.067067    0.019019    0.137137    0.051051
min      0.000000    0.000000    0.000000    0.000000    0.000000    0.000000
25%      0.000000    0.000000    0.000000    0.000000    0.000000    0.000000
50%      0.000000    0.000000    0.000000    0.000000    0.000000    0.000000
75%      0.000000    0.000000    0.000000    0.000000    0.000000    0.000000
max      1.000000    1.000000    1.000000    1.000000    1.000000    1.000000
std      0.298945    0.331026    0.250263    0.136660    0.344164    0.220212

           Western
count  999.000000
mean     0.020020
min      0.000000
25%      0.000000
50%      0.000000
75%      0.000000
max      1.000000
std      0.140139

[8 rows x 35 columns]
```

2.3 Tratando dados nulos (missing)

[ ]:
```
tabela.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 999 entries, 0 to 998
Data columns (total 76 columns):
 #   Column                        Non-Null Count  Dtype
---  ------                        --------------  -----
 0   Series_Title                  999 non-null    object
```

```
1   Released_Year                 999 non-null    datetime64[ns]
2   Certificate                   898 non-null    object
3   Runtime                       999 non-null    float64
4   Genre                         999 non-null    object
5   IMDB_Rating                   999 non-null    float64
6   Overview                      999 non-null    object
7   Meta_score                    842 non-null    float64
8   Director                      999 non-null    object
9   Star1                         999 non-null    object
10  Star2                         999 non-null    object
11  Star3                         999 non-null    object
12  Star4                         999 non-null    object
13  No_of_Votes                   999 non-null    int64
14  Gross                         830 non-null    float64
15  Star1_OscarActor_Winner       999 non-null    int64
16  Star2_OscarActor_Winner       999 non-null    int64
17  Star3_OscarActor_Winner       999 non-null    int64
18  Star4_OscarActor_Winner       999 non-null    int64
19  Director_OscarDirector_Winner 999 non-null    int64
20  Filme_OscarWinner             999 non-null    int64
21  Filme_OscarCount              999 non-null    int64
22  Budget_USD                    997 non-null    float64
23  Original_Language             998 non-null    object
24  Keywords                      998 non-null    object
25  Action                        999 non-null    int64
26  Adventure                     999 non-null    int64
27  Animation                     999 non-null    int64
28  Biography                     999 non-null    int64
29  Comedy                        999 non-null    int64
30  Crime                         999 non-null    int64
31  Drama                         999 non-null    int64
32  Family                        999 non-null    int64
33  Fantasy                       999 non-null    int64
34  Film-Noir                     999 non-null    int64
35  History                       999 non-null    int64
36  Horror                        999 non-null    int64
37  Music                         999 non-null    int64
38  Musical                       999 non-null    int64
39  Mystery                       999 non-null    int64
40  Romance                       999 non-null    int64
41  Sci-Fi                        999 non-null    int64
42  Sport                         999 non-null    int64
43  Thriller                      999 non-null    int64
44  War                           999 non-null    int64
45  Western                       999 non-null    int64
46  lang_bs                       999 non-null    bool
47  lang_cn                       999 non-null    bool
48  lang_da                       999 non-null    bool
```

```
 49  lang_de                      999 non-null    bool
 50  lang_en                      999 non-null    bool
 51  lang_es                      999 non-null    bool
 52  lang_et                      999 non-null    bool
 53  lang_fa                      999 non-null    bool
 54  lang_fr                      999 non-null    bool
 55  lang_ga                      999 non-null    bool
 56  lang_hi                      999 non-null    bool
 57  lang_id                      999 non-null    bool
 58  lang_it                      999 non-null    bool
 59  lang_ja                      999 non-null    bool
 60  lang_kn                      999 non-null    bool
 61  lang_ko                      999 non-null    bool
 62  lang_ml                      999 non-null    bool
 63  lang_nan                     999 non-null    bool
 64  lang_nl                      999 non-null    bool
 65  lang_pt                      999 non-null    bool
 66  lang_ro                      999 non-null    bool
 67  lang_ru                      999 non-null    bool
 68  lang_sh                      999 non-null    bool
 69  lang_sr                      999 non-null    bool
 70  lang_sv                      999 non-null    bool
 71  lang_ta                      999 non-null    bool
 72  lang_te                      999 non-null    bool
 73  lang_tr                      999 non-null    bool
 74  lang_uz                      999 non-null    bool
 75  lang_zh                      999 non-null    bool
dtypes: bool(30), datetime64[ns](1), float64(5), int64(29), object(11)
memory usage: 388.4+ KB
```

[ ]:
```
tabela.isna().sum()
```

[ ]:
```
Series_Title       0
Released_Year      0
Certificate      101
Runtime            0
Genre              0
                  …
lang_ta            0
lang_te            0
lang_tr            0
lang_uz            0
lang_zh            0
Length: 76, dtype: int64
```

Aqui podemos perceber que há valores nulos na tabela, nas variaveis: Certificate (101), Meta_score (157) e Gross (169). Meta-score é a média ponderada de todas as críticas. Gross é o faturamento. Certificate é a classficação etária. São valores bem expressivos dado o conjunto de dados que

possuímos, sendo assim, iremos análisar a forma adequada de realizar o tratamento. Nas colunas de orçamento, keywords e idioma original irei fazer a pesquisa dessas informações no IMDb novamente para substituir as que estão faltosas na hora do tratamento dos dados.

[ ]:
```
tabela[tabela['Budget_USD'].isna()][['Series_Title','Released_Year']]
```

[ ]:
```
          Series_Title Released_Year
252  fa yeung nin wah    2000-01-01
965         apollo 13    1995-01-01
```

[ ]:
```
tabela[tabela['Original_Language'].isna()][['Series_Title','Released_Year']]
```

[ ]:
```
    Series_Title Released_Year
965    apollo 13    1995-01-01
```

[ ]:
```
tabela[tabela['Keywords'].isna()][['Series_Title','Released_Year']]
```

[ ]:
```
    Series_Title Released_Year
965    apollo 13    1995-01-01
```

[ ]:
```
#usando chave do ano e titulo pra poder substituir
yr = pd.to_datetime(tabela['Released_Year'], errors='coerce').dt.year
m_apollo = (tabela['Series_Title'] == 'apollo 13') & (yr == 1995)
m_mood   = (tabela['Series_Title'] == 'fa yeung nin wah') & (yr == 2000)

#os valores da keywords
apollo_kw = ('space exploration, astronaut, accident, survival, malfunction,␣
 ↪rescue, '
             'houston, apollo mission, mission control, lunar module,␣
 ↪curiosity, challenge')

#agr ta preenchendo tudo q faltava
tabela.loc[m_apollo, ['Original_Language','Keywords','Budget_USD']] = ['en',␣
 ↪apollo_kw, 52_000_000]
tabela.loc[m_mood, 'Budget_USD'] = 3_000_000
```

Decidi tratar os valores nulos de Meta Score e Gross agrupando eles por genero principal, então o primeiro item da lista (ou seja, o primeiro antes da vírgula) na coluna Genero foi selecionado para o agrupamento. Ao analisar o grupo Ação, por exemplo, estimei a media de faturamento e media de avaliação/criticas desse gênero e imputei nos valores nulos. O restante, que não havia como imputar, coloquei a mediana global.

[ ]:
```
#pego o genero principal q é o primeiro da lista
tabela["Genero_Principal"] = tabela["Genre"].str.split(",").str[0].str.strip()

#calcula a media do gross pra cada genero
media_gross_por_genero = tabela.groupby("Genero_Principal")["Gross"].mean()
```

```
#preenche os valores vazios do gross com a media do genero
tabela["Gross"] = tabela["Gross"].fillna(tabela["Genero_Principal"].
 ↪map(media_gross_por_genero))

# se ainda sobrar vazio coloco a mediana geral do gross
mediana_global_gross = tabela["Gross"].median(skipna=True)
tabela["Gross"] = tabela["Gross"].fillna(mediana_global_gross)
```

[ ]:
```
#clculo a media do meta_score pra cada genero
media_meta_por_genero = tabela.groupby("Genero_Principal")["Meta_score"].mean()

#preencher os valores vazios do meta_score com a media do genero
tabela["Meta_score"] = tabela["Meta_score"].fillna(tabela["Genero_Principal"].
 ↪map(media_meta_por_genero))

#se ainda sobrar vazio coloco a mediana geral do meta_score
mediana_global_meta = tabela["Meta_score"].median(skipna=True)
tabela["Meta_score"] = tabela["Meta_score"].fillna(mediana_global_meta)

tabela.isna().sum()
```

[ ]:
```
Series_Title          0
Released_Year         0
Certificate         101
Runtime               0
Genre                 0
                   …
lang_te               0
lang_tr               0
lang_uz               0
lang_zh               0
Genero_Principal      0
Length: 77, dtype: int64
```

2.4 Feature

[ ]:
```
#criar a variavel profit
tabela["Profit"] = tabela["Gross"] - tabela["Budget_USD"]

#ver as primeiras linhas pra conferir
print(tabela[["Series_Title", "Profit"]].head())
```

```
                                Series_Title       Profit
0                             the godfather  128966411.0
1                           the dark knight  349858444.0
2                    the godfather: part ii   44300000.0
3                                12 angry men    3962249.0
```

```
4  the lord of the rings: the return of the king  283845905.0
```

3 EDA

3.1 Variável alvo

[ ]:
```
sns.histplot(tabela['IMDB_Rating'], bins=20, kde=True)
plt.title("Distribuição das notas IMDB")
plt.show()
```

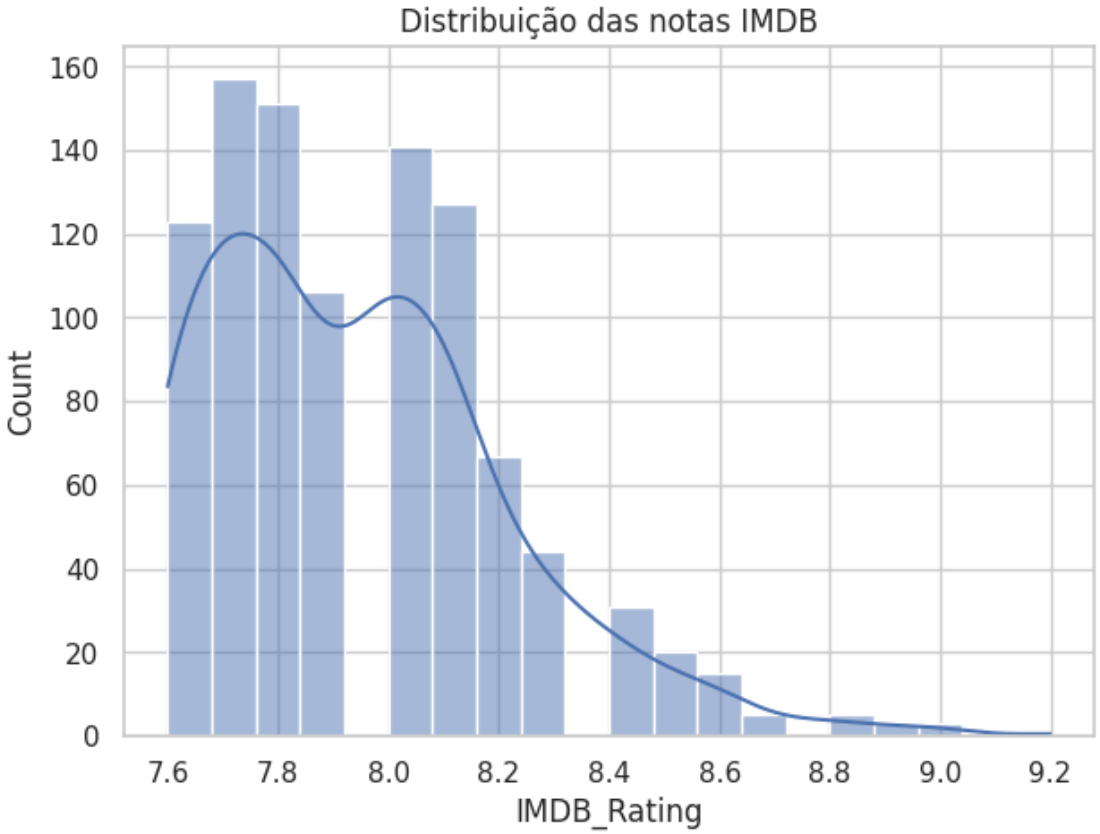

A maioria dos filmes tem notas entre 7.6 e 8.2, com pico em torno de 7.8. Poucos chegam acima de 8.5, mostrando que notas muito altas são raras.

[ ]:
```
# Selecionar apenas colunas relevantes (tirando gêneros e Oscars de atores)
subset =␣
  ↪tabela[['IMDB_Rating','Meta_score','No_of_Votes','Gross','Budget_USD','Runtime']]

# Pairplot
sns.pairplot(subset, diag_kind="kde", corner=True, plot_kws={"alpha":0.5, "s":
  ↪20})
plt.suptitle("Dispersão entre Variáveis Relevantes", y=1.02)
```

```
plt.show()
```

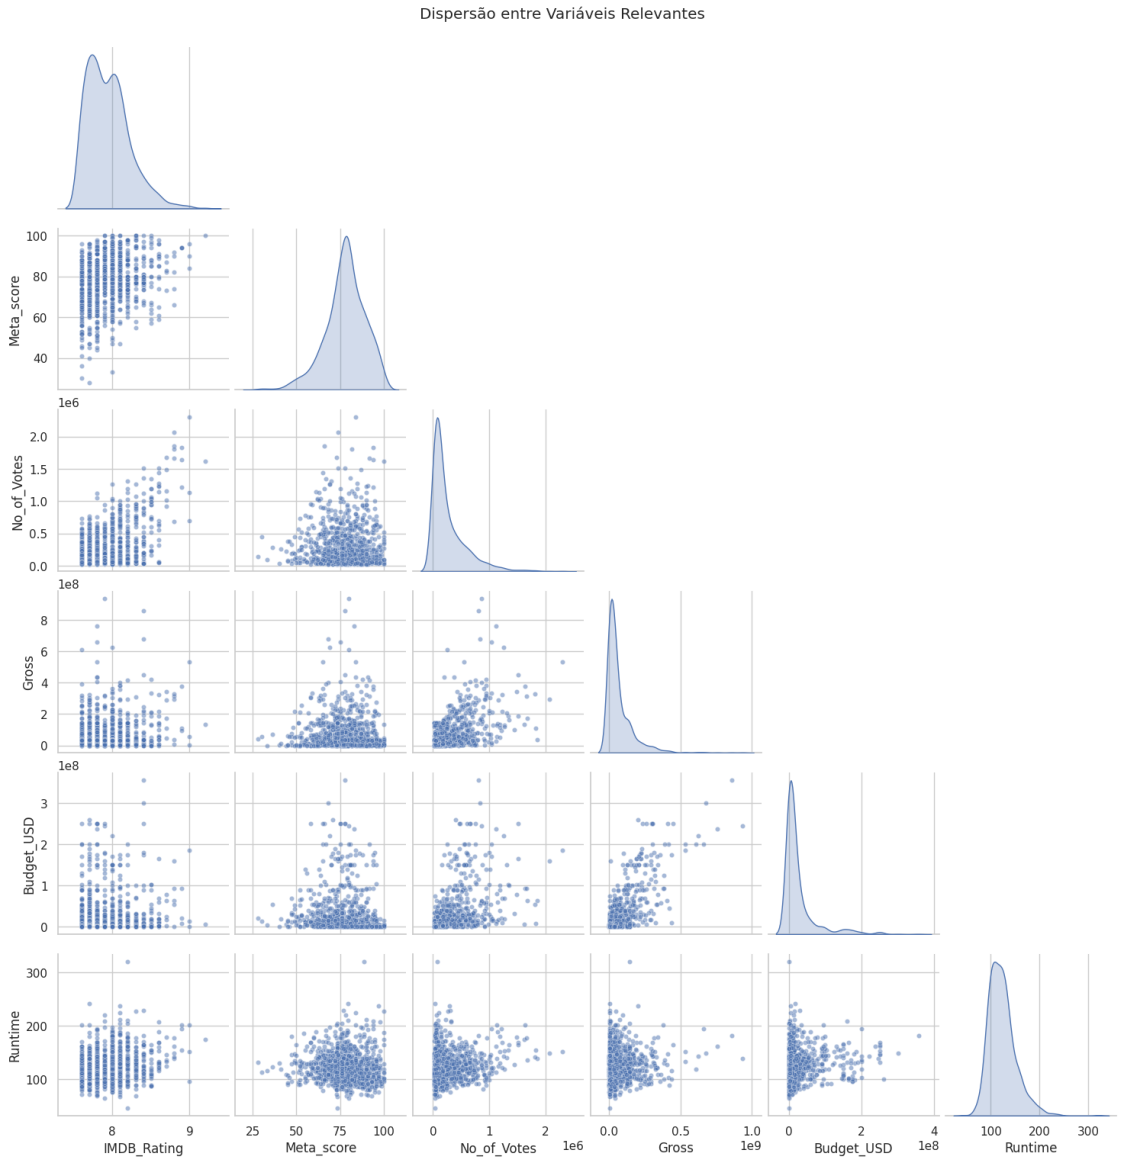

os filmes que tem mais votos acabam ficando com notas mais estaveis no imdb, ja o orcamento maior geralmente puxa junto uma bilheteria maior. a duracao do filme e as notas da critica nao mostram um padrao muito claro com o resto.

[ ]:
```
sns.set(style='whitegrid')
plt.rcParams["figure.figsize"] = (7, 5)

def plot_scatter_with_corr(x_col, y_col, data, title_prefix):
    r, _ = pearsonr(data[x_col], data[y_col])
```

```
    sns.lmplot(x=x_col, y=y_col, data=data, aspect=1.2, height=5,␣
 ↪scatter_kws={'alpha':0.5})
    plt.title(f'{title_prefix}\nCorrelação de Pearson: r = {r:.2f}')
    plt.tight_layout()
    plt.show()

# 1. IMDb Rating vs Meta Score
plot_scatter_with_corr('IMDB_Rating', 'Meta_score', tabela, 'IMDb Rating vs␣
 ↪Meta Score')

# 2. IMDb Rating vs Nº de Votos
plot_scatter_with_corr('IMDB_Rating', 'No_of_Votes', tabela, 'IMDb Rating vs Nº␣
 ↪de Votos')

# 3. IMDb Rating vs Budget
plot_scatter_with_corr('IMDB_Rating', 'Budget_USD', tabela, 'IMDb Rating vs␣
 ↪Budget')

# 4. IMDb Rating vs Gross
plot_scatter_with_corr('IMDB_Rating', 'Gross', tabela, 'IMDb Rating vs Gross')

# 6. IMDb Rating vs Runtime
plot_scatter_with_corr('IMDB_Rating', 'Runtime', tabela, 'IMDb Rating vs␣
 ↪Runtime')
```

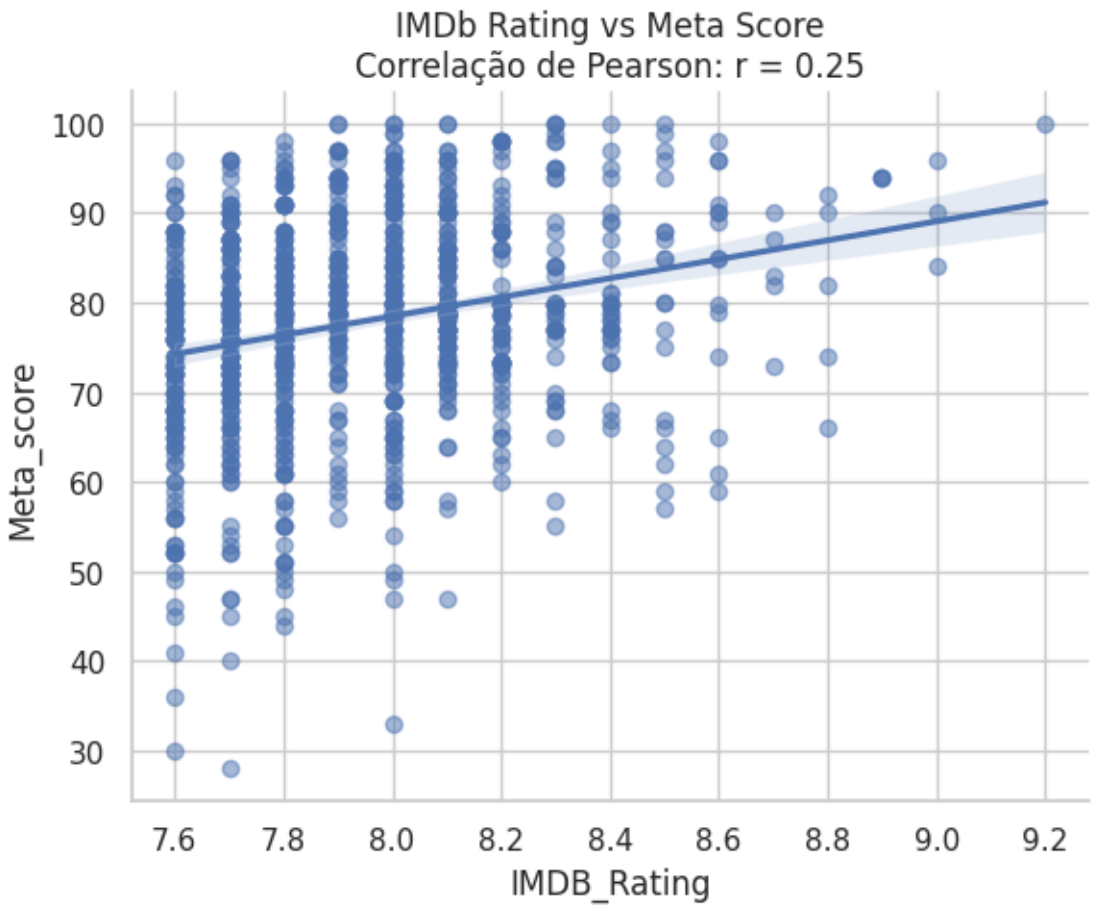
IMDb Rating vs Meta Score
Correlação de Pearson: r = 0.25
Meta_score
IMDB_Rating
100
90
80
70
60
50
40
30
7.6
7.8
8.0
8.2
8.4
8.6
8.8
9.0
9.2

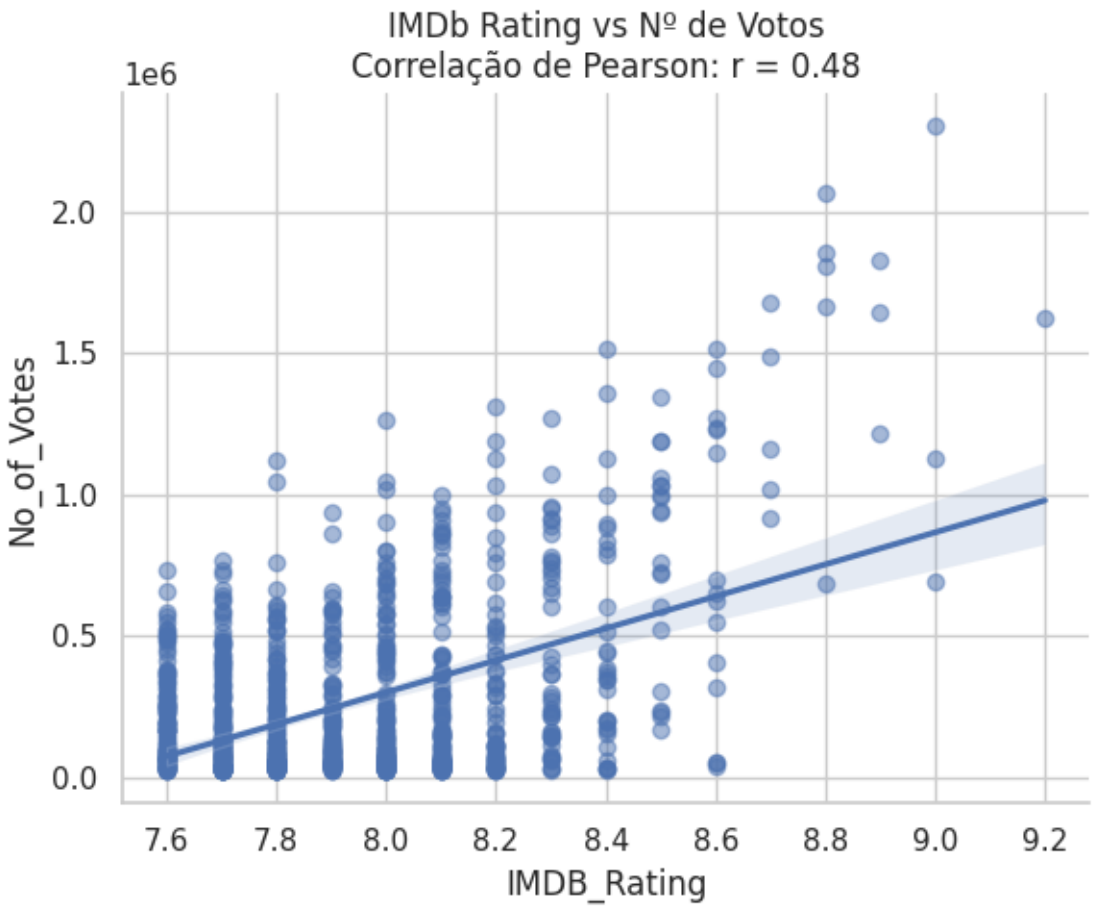
IMDb Rating vs Nº de Votos
Correlação de Pearson: r = 0.48
1e6
2.0
1.5
1.0
0.5
0.0
No_of_Votes
7.6
7.8
8.0
8.2
8.4
8.6
8.8
9.0
9.2
IMDB_Rating

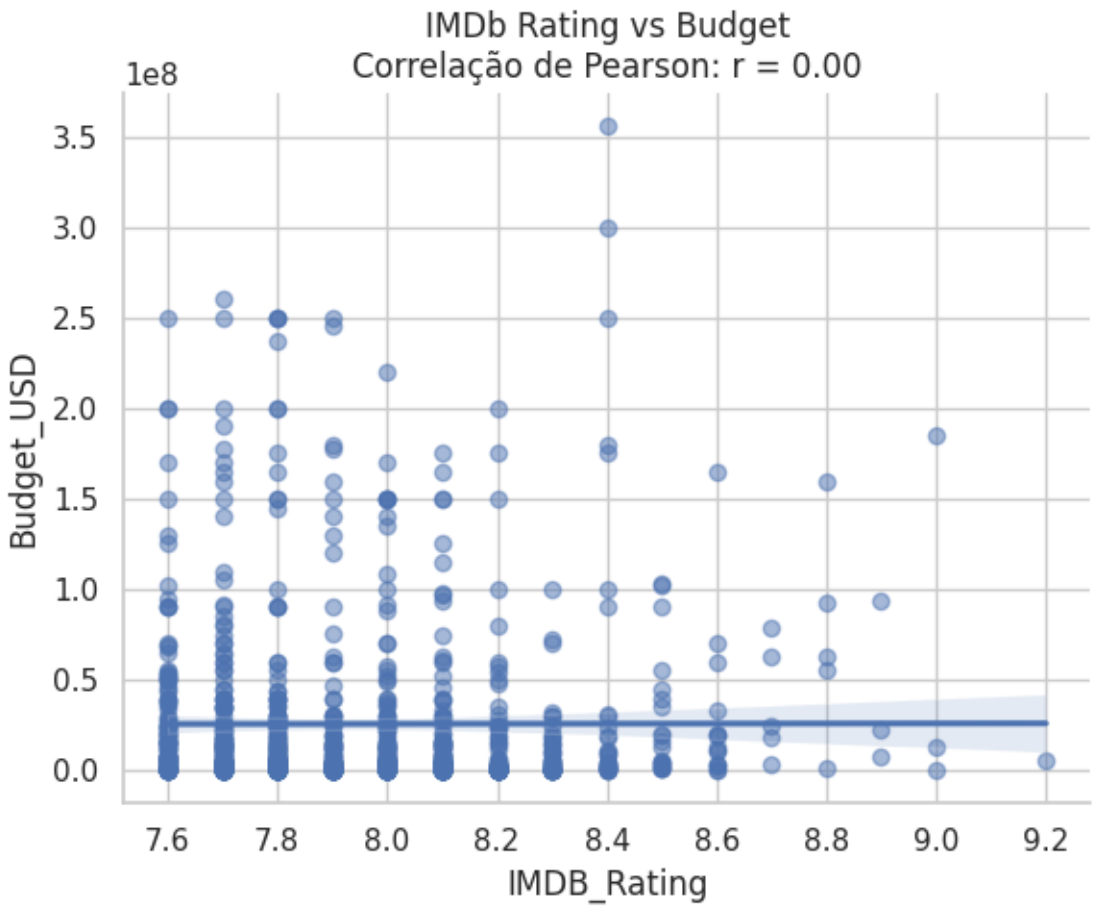
IMDb Rating vs Budget
Correlação de Pearson: r = 0.00
1e8
3.5
3.0
2.5
2.0
1.5
1.0
0.5
0.0
Budget_USD
7.6
7.8
8.0
8.2
8.4
8.6
8.8
9.0
9.2
IMDB_Rating

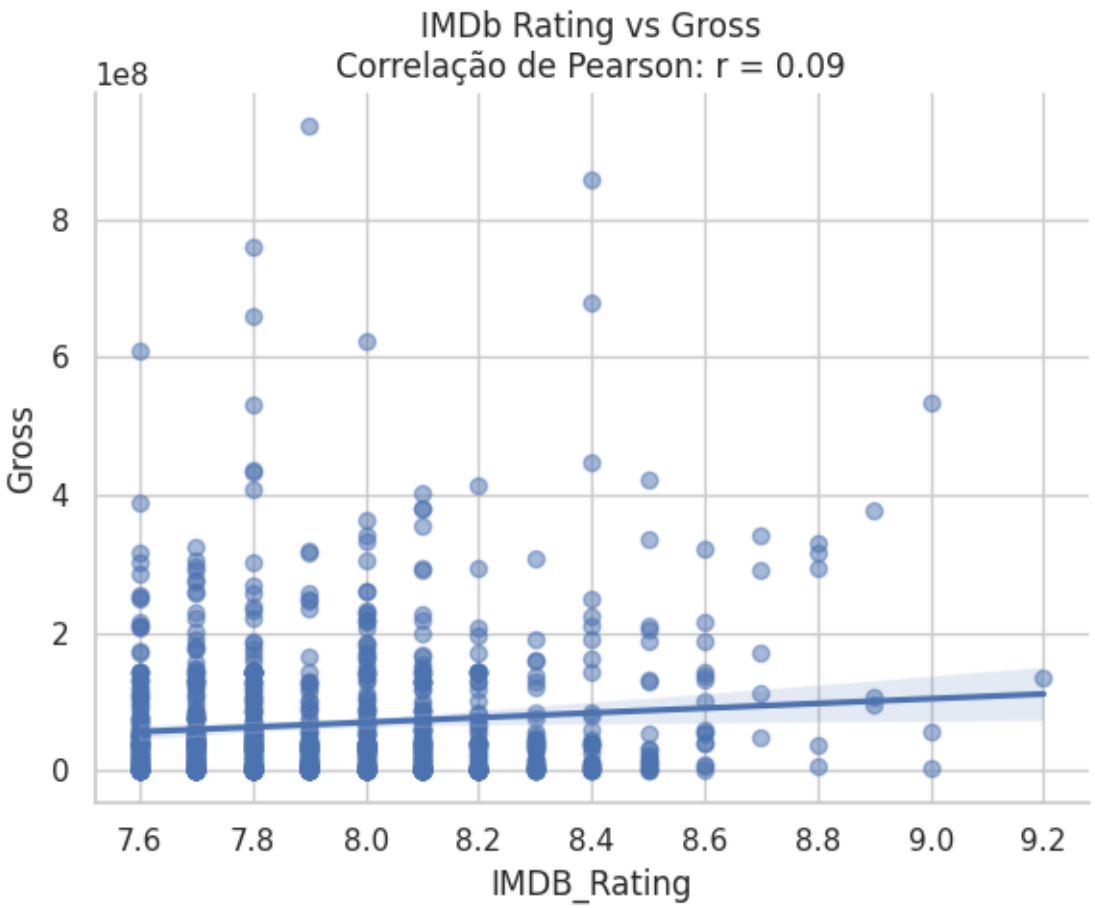
IMDb Rating vs Gross
Correlação de Pearson: r = 0.09
1e8
8
6
4
2
0
Gross
7.6
7.8
8.0
8.2
8.4
8.6
8.8
9.0
9.2
IMDB_Rating

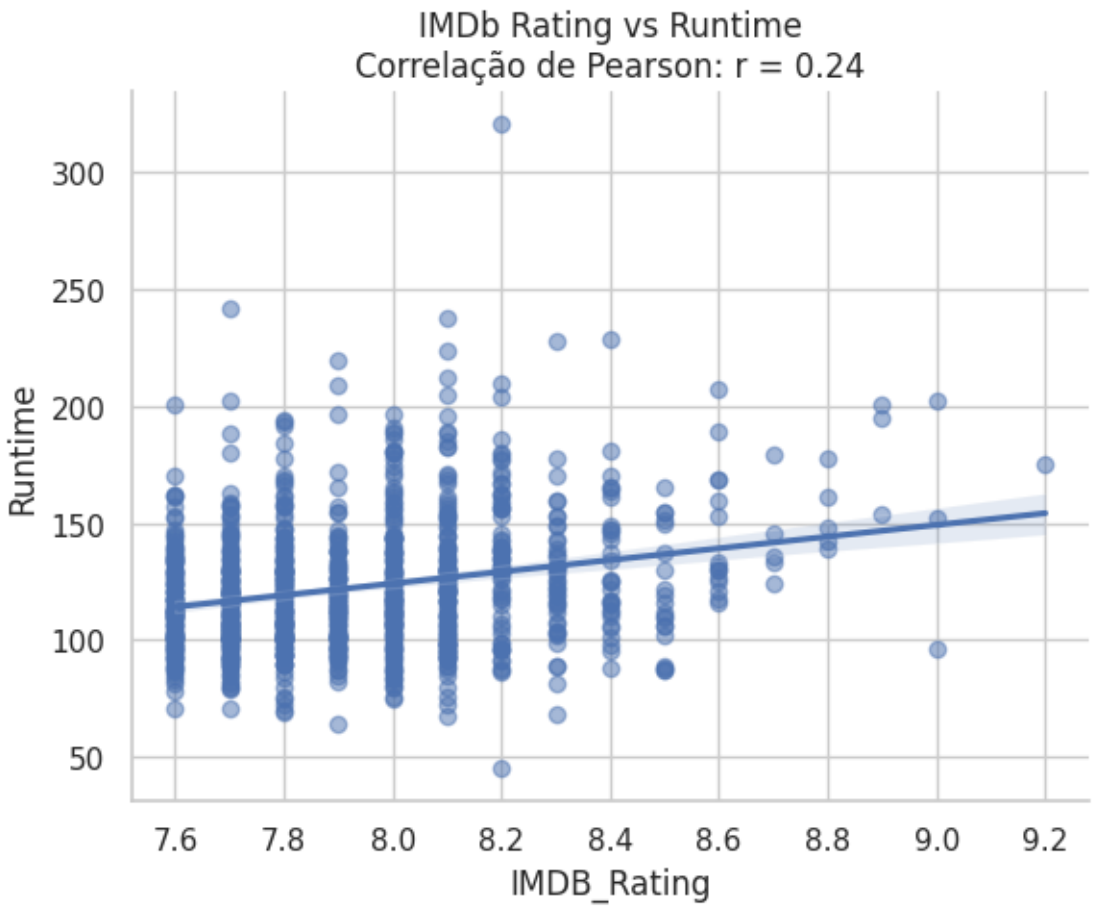

as notas do imdb tem uma ligação fraca com o meta score e também com o tempo de duração dos filmes, mas nada muito forte. a relação que aparece mais clara é com o número de votos, mostrando que filmes bem avaliados costumam ter mais público engajado. já o orçamento e a bilheteria praticamente não influenciam na nota, gastar mais ou arrecadar mais não garante uma avaliação melhor.

[ ]:
```
# Explodir gêneros em linhas (um filme pode ter mais de 1)
tabela_exploded = tabela.assign(Genre=tabela['Genre'].str.split(', ')).
 ↪explode('Genre')

# Boxplot simples
sns.boxplot(data=tabela_exploded, x='Genre', y='IMDB_Rating')
plt.xticks(rotation=90)
plt.title("Notas IMDb por Gênero")
plt.show()
```

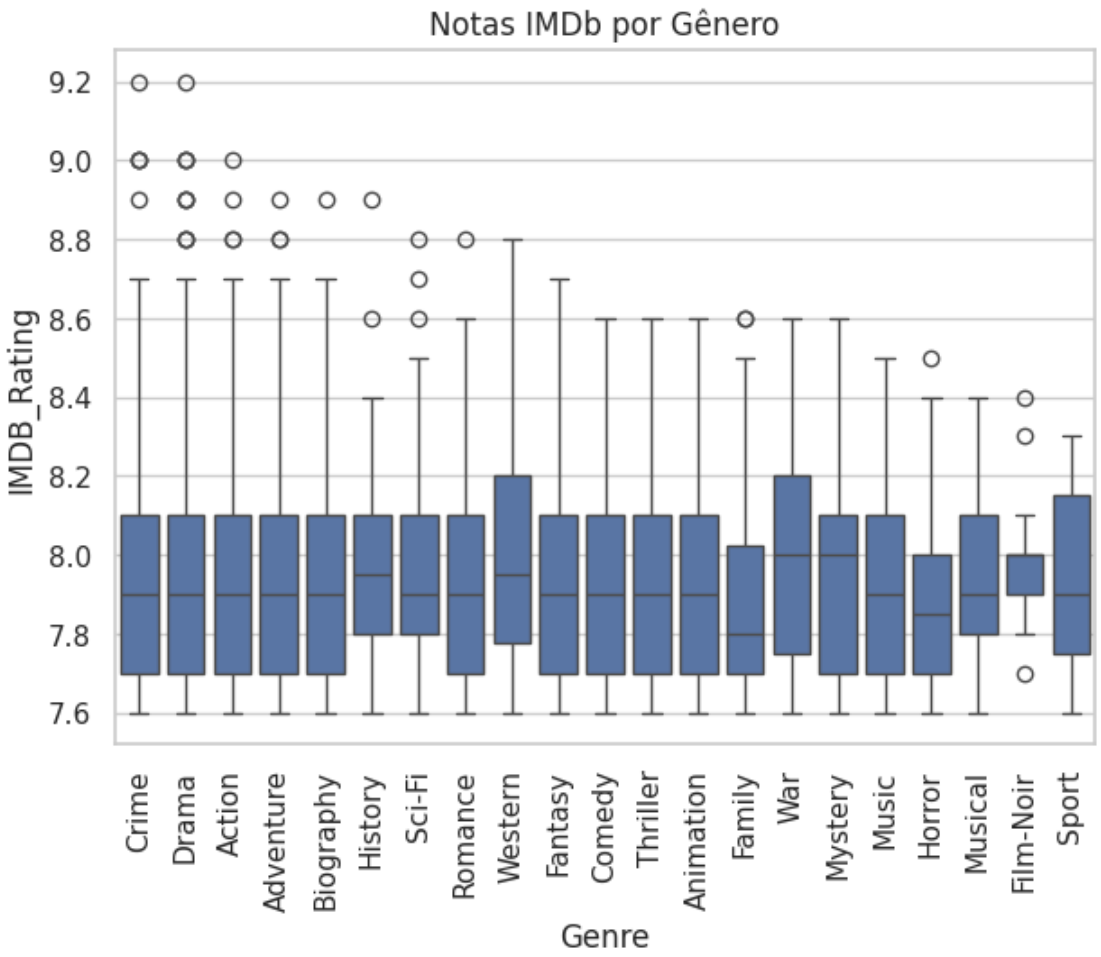

as notas do imdb ficam bem proximas entre os generos, a maioria variando entre 7.7 e 8.1. crime, drama e biography puxam um pouco mais pra cima, com varios filmes chegando perto de 9. ja generos como horror, musical e animation costumam ter medias mais baixas, mostrando que agradam menos em geral.

3.2 Exploração da estrutura dos dados

[ ]:
```
# Contagem de idiomas
idiomas_count = tabela['Original_Language'].value_counts(dropna=False)

print(idiomas_count)
```

```
Original_Language
en     698
hi      54
ja      48
fr      44
```

```
it      21
de      20
es      18
ko      14
sv      12
tr      10
ru      10
da       8
cn       6
zh       5
pt       4
fa       4
nl       3
ta       3
te       2
sr       2
ar       2
id       2
et       1
sh       1
ml       1
nan      1
ga       1
ro       1
bs       1
uz       1
kn       1
Name: count, dtype: int64
```

[ ]:
```python
#agrupar por ano e calcular medias
df_anos = tabela.groupby("Released_Year")[["Budget_USD","Gross","Profit"]].
  ↪mean().reset_index()

#plotar linhas
plt.figure(figsize=(12,6))
plt.plot(df_anos["Released_Year"], df_anos["Budget_USD"], label="budget")
plt.plot(df_anos["Released_Year"], df_anos["Gross"], label="gross")
plt.plot(df_anos["Released_Year"], df_anos["Profit"], label="profit")

plt.xlabel("ano de lancamento")
plt.ylabel("valor medio em usd")
plt.title("evolucao de budget, gross e profit ao longo dos anos")
plt.legend()
plt.tight_layout()
plt.show()
```

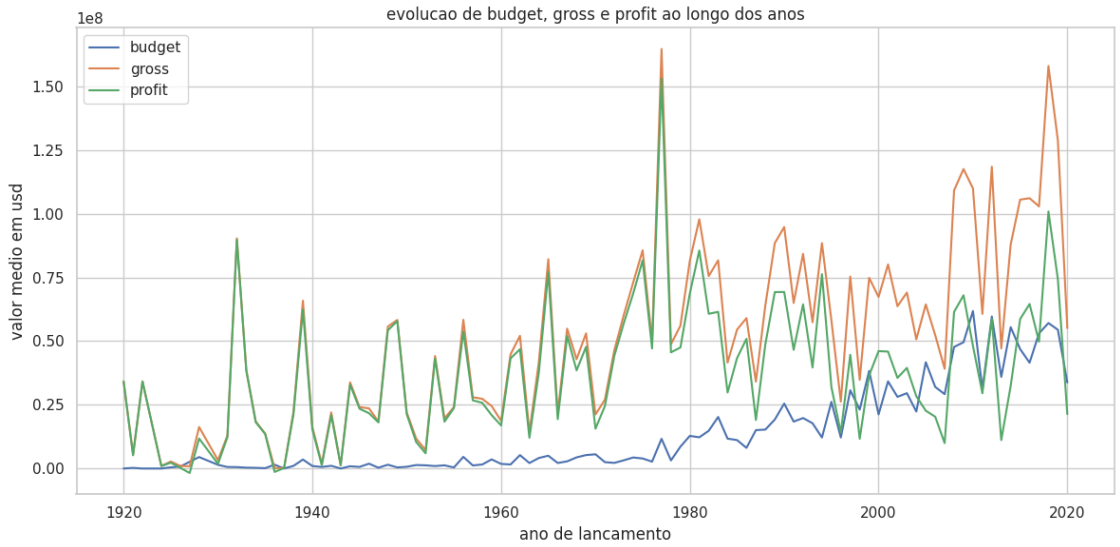

O gráfico mostra a evolução do orçamento (budget), da receita bruta (gross) e do lucro estimado (profit) ao longo dos anos de lançamento dos filmes.
Nota-se que a partir de 1970 os valores aumentam, mas as oscilações em gross e profit são muito acentuadas. Esse comportamento pode refletir tanto filmes de grande sucesso quanto problemas de consistência nos dados, já que a base não possui registros uniformes em todas as décadas.
Além disso, há um volume muito maior de filmes lançados após 1990, o que tende a tornar as médias mais estáveis nesse período, em contraste com os anos anteriores em que poucos filmes registrados fazem com que os valores médios oscilem bastante.
Portanto, os resultados precisam ser interpretados com cautela, pois parte das variações pode estar associada às limitações da base de dados e não apenas a mudanças reais no mercado cinematográfico.

[ ]:
```
corr = tabela[genero_cols].corr()

#heatmap
plt.figure(figsize=(10,8))
plt.imshow(corr, cmap="coolwarm", vmin=-1, vmax=1)
plt.xticks(range(len(corr.columns)), corr.columns, rotation=90)
plt.yticks(range(len(corr.index)), corr.index)
plt.colorbar(label="Correlação")
plt.title("Correlação entre gêneros (dummies)")
plt.tight_layout()
plt.show()

#ranking sem repetição (só triângulo superior)
mask = np.triu(np.ones(corr.shape, dtype=bool), k=1)
pairs = corr.where(mask).stack().sort_values()

print("\nTop 5 correlações negativas:")
print(pairs.head(5).to_string())
```

```
print("\nTop 5 correlações positivas:")
print(pairs.tail(5)[::-1].to_string())
```

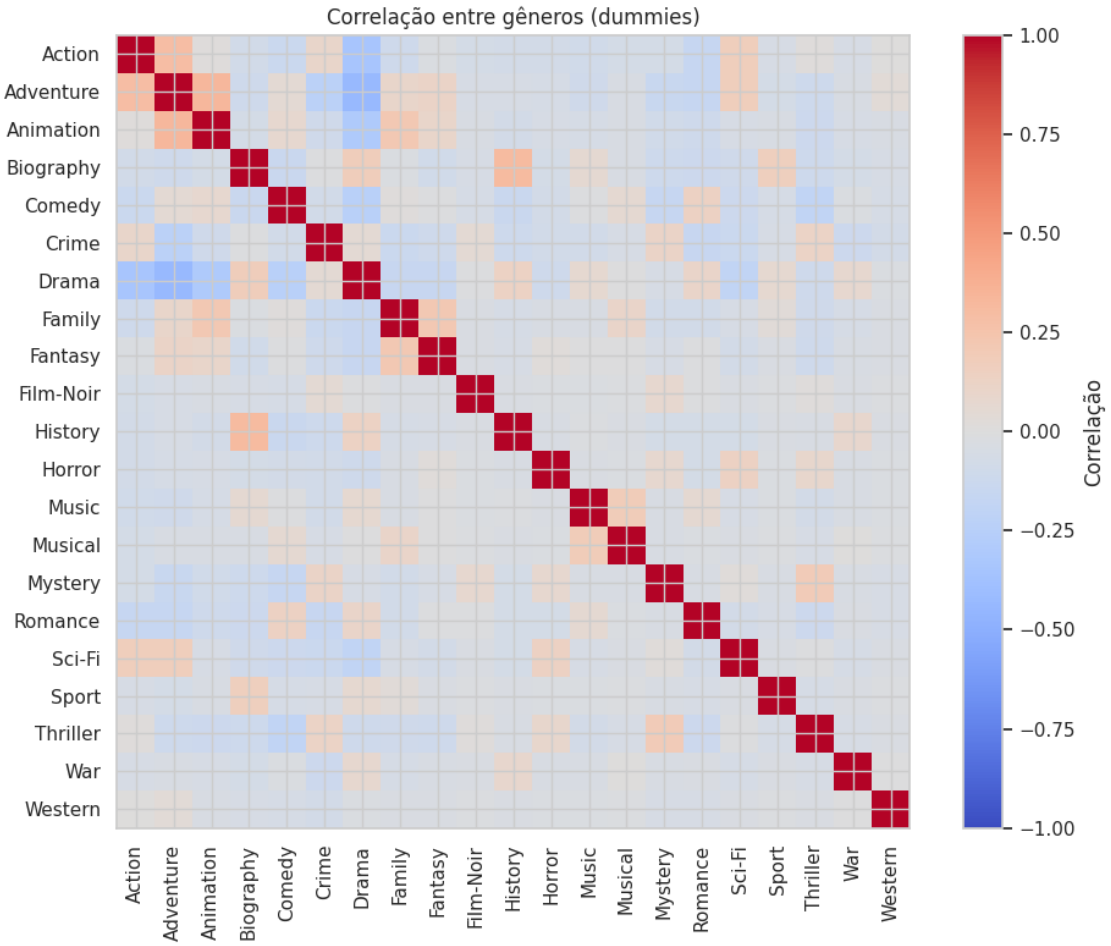


```
Top 5 correlações negativas:
Adventure  Drama   -0.433211
Action     Drama   -0.341705
Animation  Drama   -0.304570
Comedy     Drama   -0.241533
Adventure  Crime   -0.229326

Top 5 correlações positivas:
Adventure  Animation    0.329782
Biography  History      0.305528
Action     Adventure    0.295528
Family     Fantasy      0.215486
Animation  Family       0.212490
```

O heatmap indica que drama costuma aparecer separado de gêneros de apelo popular como adventure, action, animation e comedy, e também há certa separação entre adventure e crime. Entre as combinações que tendem a caminhar juntas destacam-se adventure com animation, action com adventure e a dupla tematicamente próxima biography com history; pares voltados ao público familiar, como family com fantasy e animation com family, também aparecem com mais coocorrência. Já horror, musical e film-noir surgem mais isolados do restante, com pouca associação aos outros gêneros.

[ ]:
```
#seleciona apenas as colunas numericas
num_cols = tabela.select_dtypes(include='number')

#matriz de correlação
corr = num_cols.corr()

#deixa só a parte triangular superior
corr_unstacked = corr.where(np.triu(np.ones(corr.shape), k=1).astype(bool))

#transforma em série
corr_pairs = corr_unstacked.unstack().dropna()

#ordena pelos mais fortes
corr_sorted = corr_pairs.reindex(corr_pairs.abs().sort_values(ascending=False).
 ↪index)

# Mostra top 10
print("Top correlações mais fortes:")
print(corr_sorted.head(10))
```

```
Top correlações mais fortes:
Profit            Gross                          0.905485
Budget_USD        Gross                          0.749003
Filme_OscarCount  Filme_OscarWinner              0.748209
Gross             No_of_Votes                    0.554287
Filme_OscarCount  Director_OscarDirector_Winner  0.541023
Budget_USD        No_of_Votes                    0.522541
No_of_Votes       IMDB_Rating                    0.479308
Adventure         Budget_USD                     0.478456
                  Gross                          0.440677
Drama             Adventure                     -0.433211
dtype: float64
```

as correlações mais fortes mostram que quanto maior o orçamento, maior tende a ser a bilheteria, e filmes que arrecadam mais também costumam ter mais votos no imdb. além disso, filmes de aventura aparecem ligados a altos orçamentos e faturamentos. já o drama tem correlação negativa com aventura e ação, indicando que esses gêneros raramente aparecem juntos.

[ ]:
```
#selecionar todas as colunas numericas
num_cols = tabela.select_dtypes(include='number')
```

```
#correlação contra a nota IMDb
corr_target = num_cols.corrwith(tabela['IMDB_Rating']).
 ↪sort_values(ascending=False)

plt.figure(figsize=(6,8))
sns.barplot(x=corr_target.values, y=corr_target.index, orient='h')
plt.title("Correlação de variáveis numéricas (incl. dummies) com IMDB_Rating")
plt.show()
```

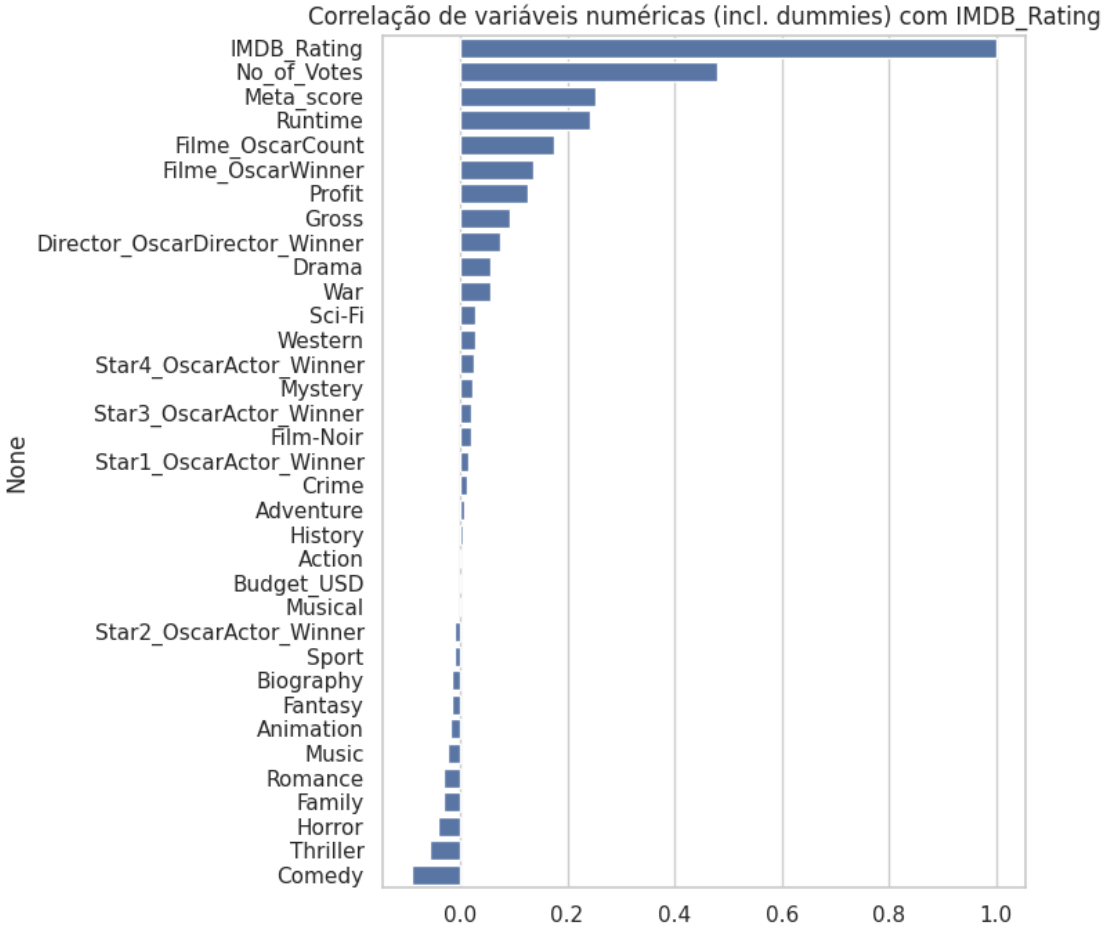

as variáveis que mais se relacionam com a nota do imdb são o número de votos, o meta score e o tempo de duração dos filmes. fatores como bilheteria, orçamento ou até mesmo gêneros específicos aparecem com pouca ou quase nenhuma correlação, mostrando que a recepção do público depende mais de engajamento e avaliação crítica do que de investimento financeiro.

[ ]:
```
generos = tabela['Genre'].str.get_dummies(sep=', ').sum().
 ↪sort_values(ascending=False)
```

```
generos.plot.bar(color='skyblue')
plt.title("Quantidade de filmes por gênero")
plt.ylabel("Nº de filmes")
plt.show()
```

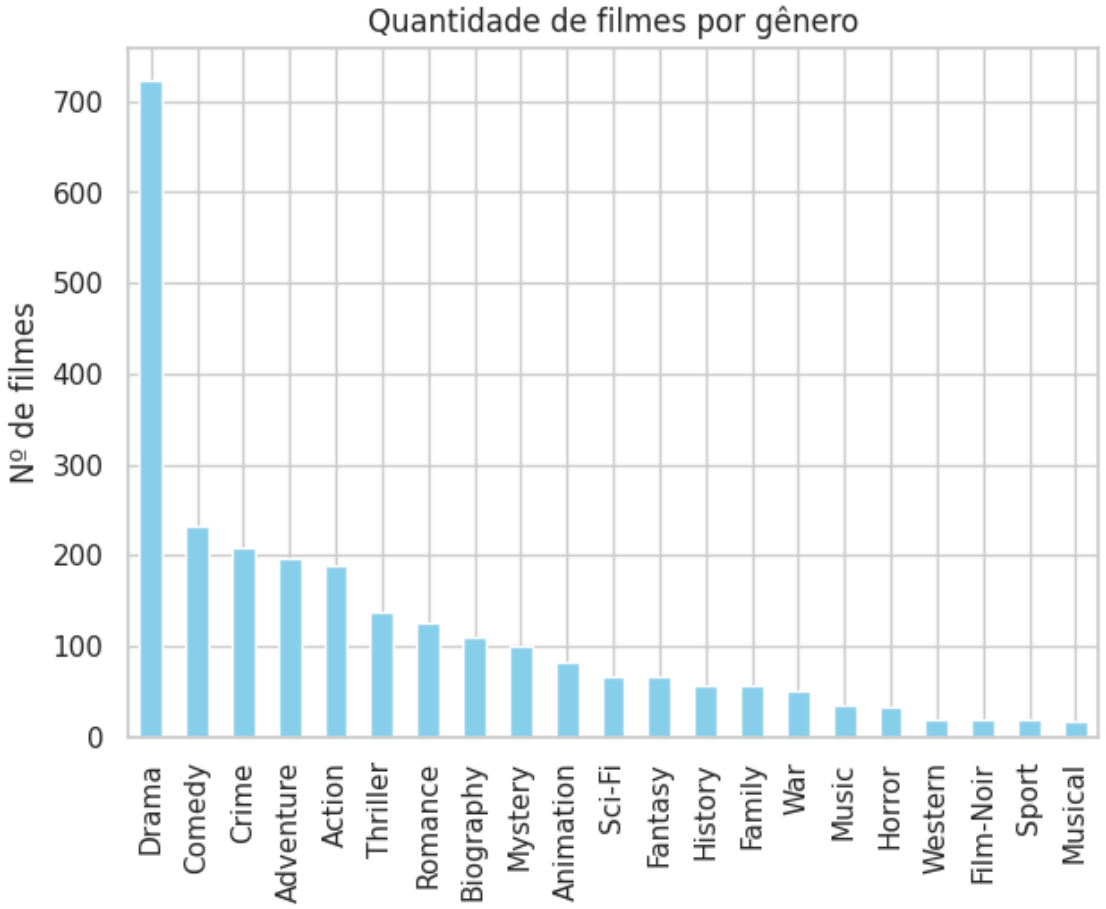

o gênero drama domina de longe em quantidade de filmes, seguido por comedy e crime. generos como musical, sport e film-noir aparecem bem pouco, mostrando que sao nichados e muito menos explorados na produçao cinematográfica.

[ ]:
```
#transformar pra datetime e tirar o ano
anos_temp = pd.to_datetime(tabela["Released_Year"], errors="coerce").dt.year

#criar decada com base nesses anos
decadas_temp = (anos_temp // 10 * 10).astype("Int64").astype(str) + "s"

#pegar o genero principal antes da virgula
generos_temp = tabela["Genre"].astype(str).str.split(",").str[0].str.strip()
```

```
#criar dataframe temporario
temp = pd.DataFrame({"Decada": decadas_temp, "Genero": generos_temp})

#tirar linhas com decada nula
temp = temp[temp["Decada"].notna()]

#agrupar por decada e genero
genero_por_decada = temp.groupby(["Decada", "Genero"]).size().
 ↪unstack(fill_value=0)

#ordenar decadas certinho
genero_por_decada.index = genero_por_decada.index.str.replace("s", "").
 ↪astype(int)
genero_por_decada = genero_por_decada.sort_index()
genero_por_decada.index = genero_por_decada.index.astype(str) + "s"

#plotar grafico
genero_por_decada.plot(kind="bar", stacked=True, figsize=(12, 6))
plt.title("distribuicao dos generos por decada")
plt.xlabel("decada")
plt.ylabel("qtd filmes")
plt.xticks(rotation=0)
plt.tight_layout()
plt.show()
```

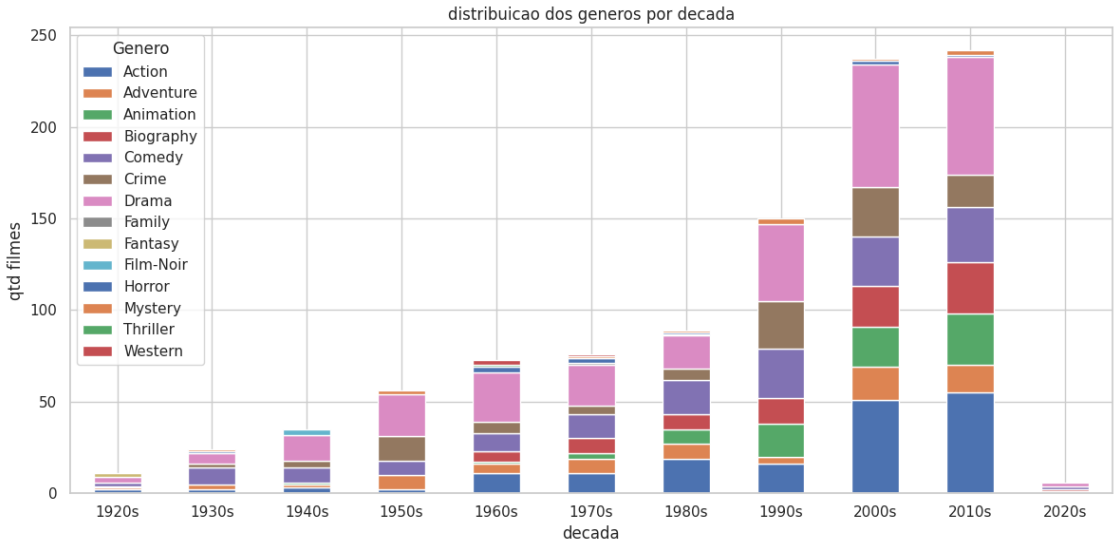

[ ]:
```
#boxplot de Gross por classificação etaria
sns.boxplot(data=tabela, x='Certificate', y='Gross')
plt.title("Distribuição do Faturamento por Classificação Etária")
```

```
plt.xlabel("Classificação Etária")
plt.ylabel("Faturamento (Gross)")
plt.show()
```

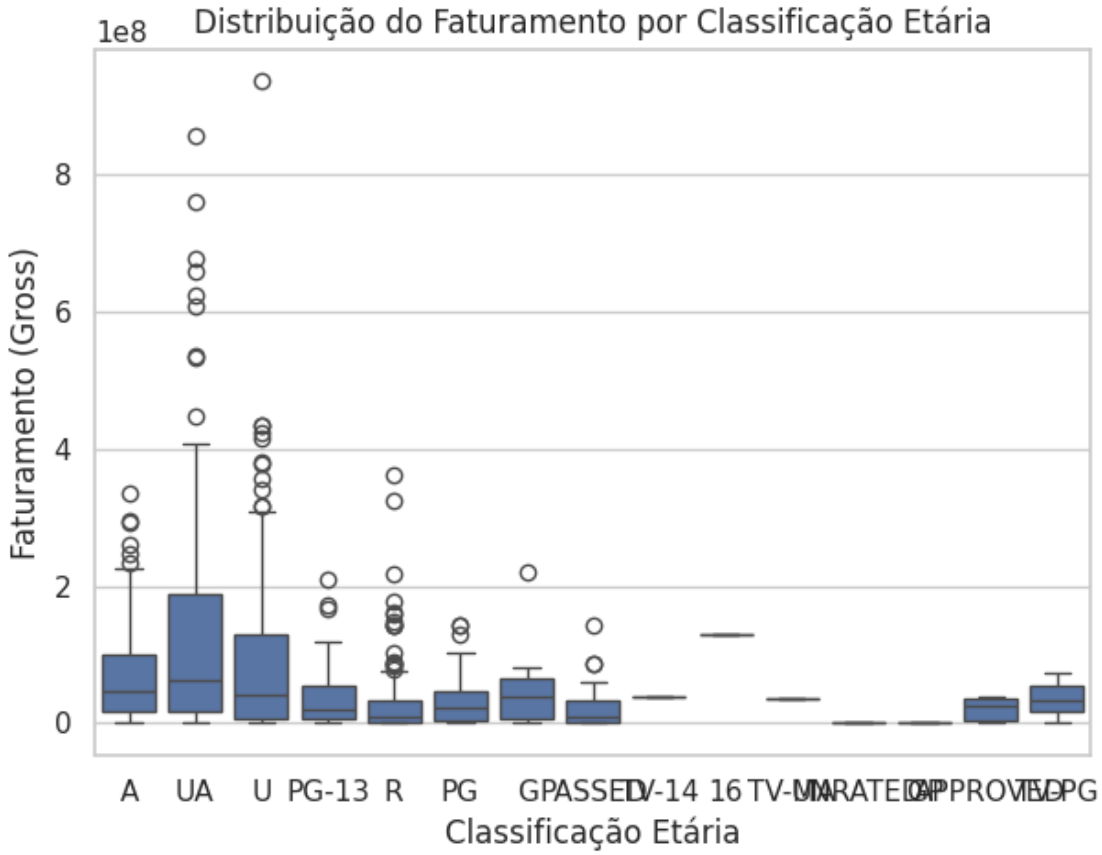

os filmes com classificacao A, UA e U sao os que mais se destacam em faturamento, chegando a bilheterias muito altas em alguns casos. ja os de classificacao PG, R e outras costumam render menos, mostrando que produções mais acessiveis pro publico amplo tendem a ter melhor desempenho financeiro.

4 Hipóteses

4.1 Será que Adventure + Action, além de terem alto faturamento quando analisados separadamente, também mantêm ou melhoram seu desempenho em termos de avaliação no IMDb quando aparecem combinados?

os resultados mostram que adventure e action isolados ou combinados não apresentam diferença significativa nas notas do público (imdb), ficando todos em torno de 7.9. no entanto, quando olhamos para o faturamento, esses gêneros se destacam fortemente: adventure+action tem média de bilheteria mais que o dobro dos demais, mostrando grande poder comercial. já ao adicionar o drama, a nota média do imdb sobe para 8.15, a maior entre os grupos, embora essa diferença

não tenha sido estatisticamente significativa, sugerindo apenas uma tendência. do lado da crítica especializada (meta_score), encontramos diferenças claras: filmes de action puro recebem avaliações mais baixas (~72), enquanto adventure e especialmente adventure+action+drama chegam perto de 80 pontos, sendo os mais valorizados pelos críticos. em resumo, adventure+action é a combinação mais lucrativa, mas adventure+action+drama tende a reunir melhor avaliação tanto do público quanto da crítica.

[ ]:
```
#separar generos em linha
tabela_exploded = tabela.assign(Genre=tabela["Genre"].str.split(", ")).
 ↪explode("Genre")

#organizar faturamento medio por genero
media_gross = tabela_exploded.groupby("Genre")["Gross"].mean().
 ↪sort_values(ascending=False)

#grafico
media_gross.plot.bar(color="orange")
plt.title("faturamento medio por genero")
plt.ylabel("faturamento medio (gross)")
plt.show()
```

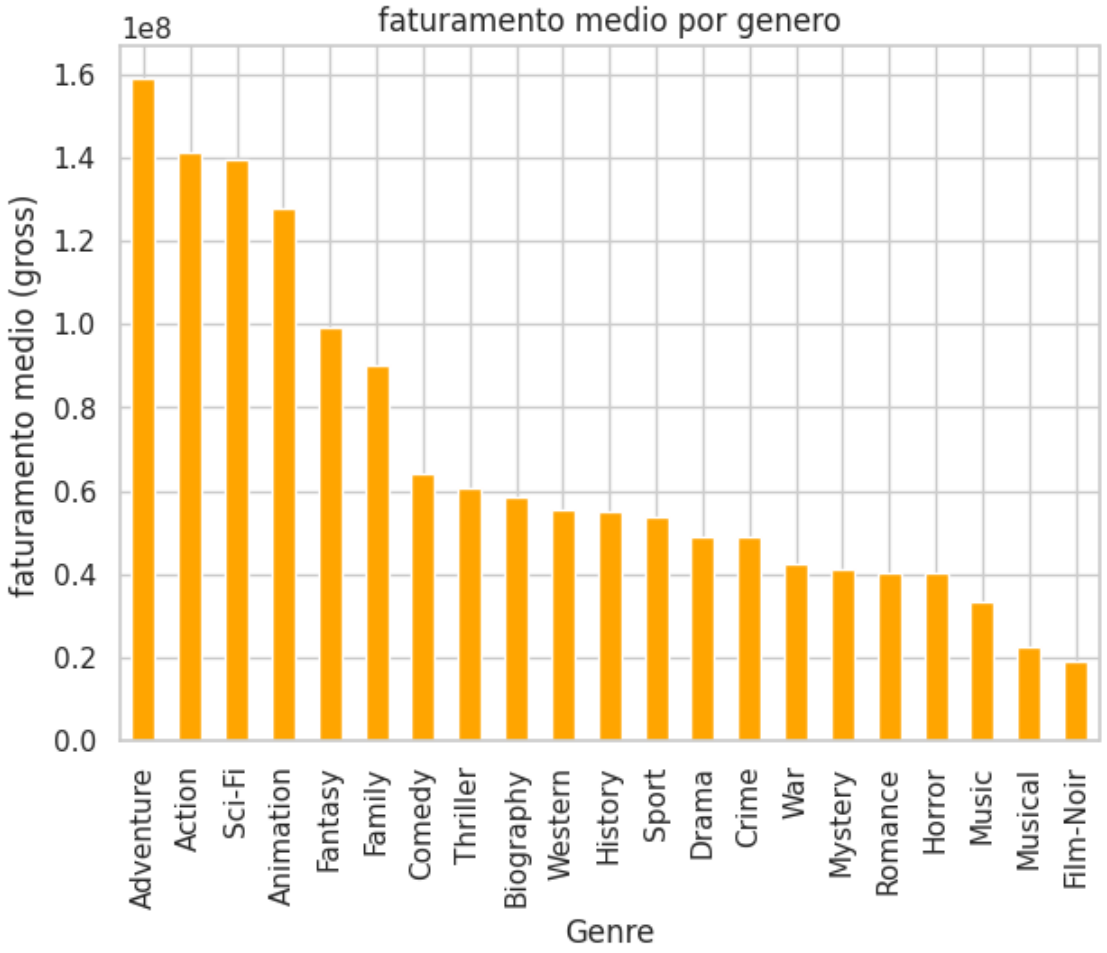

[ ]:
```
# Agrupar combinações
combo_stats = tabela.groupby('Genre').agg(
    qtd_filmes=('IMDB_Rating', 'count'),
    media_rating=('IMDB_Rating', 'mean'),
    media_votos=('No_of_Votes', 'mean')
).reset_index()

# Pegar só as 20 combinações mais frequentes
top_combos = combo_stats.sort_values('qtd_filmes', ascending=False).head(20)

# Gráfico de bolhas
plt.figure(figsize=(12,7))
plt.scatter(
    top_combos['media_rating'],
    top_combos['qtd_filmes'],
    s=top_combos['media_votos']/500,  # bolha proporcional à popularidade
    alpha=0.6, edgecolors="k"
)

# Nome das combinações ao lado das bolhas
for i, row in top_combos.iterrows():
    plt.text(row['media_rating']+0.01, row['qtd_filmes'], row['Genre'],␣
 ↪fontsize=8)

plt.xlabel("Média IMDb")
plt.ylabel("Quantidade de Filmes")
plt.title("Sucesso das Combinações de Gêneros (Top 20)")
plt.show()
```

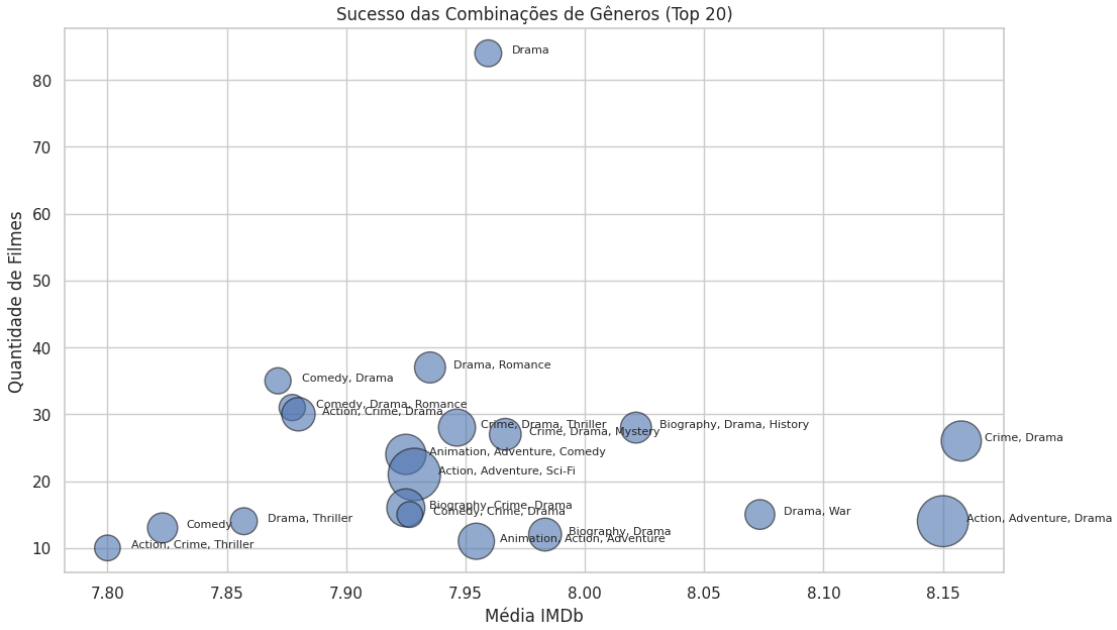

[ ]:
```
# criar coluna de grupo baseado nos gêneros
def classifica_genero(row):
    genres = str(row['Genre'])  # ou a coluna que junta os gêneros
    if 'Adventure' in genres and 'Action' in genres:
        return 'Adventure+Action'
    elif 'Adventure' in genres:
        return 'Adventure'
    elif 'Action' in genres:
        return 'Action'
    else:
        return 'Outros'

tabela['Grupo_Genero'] = tabela.apply(classifica_genero, axis=1)

# criar listas com as notas IMDb por grupo
ratings_adventure = tabela.loc[tabela['Grupo_Genero'] == 'Adventure',␣
 ↪'IMDB_Rating']
ratings_action = tabela.loc[tabela['Grupo_Genero'] == 'Action', 'IMDB_Rating']
ratings_both = tabela.loc[tabela['Grupo_Genero'] == 'Adventure+Action',␣
 ↪'IMDB_Rating']
ratings_outros = tabela.loc[tabela['Grupo_Genero'] == 'Outros', 'IMDB_Rating']

# 3) ANOVA
F, p = f_oneway(ratings_adventure, ratings_action, ratings_both, ratings_outros)
print(f"ANOVA: F = {F:.3f} | p-valor = {p:.4f}")
```

```
# 4)medias por grupo
print(tabela.groupby('Grupo_Genero')['IMDB_Rating'].mean())
```

```
ANOVA: F = 0.303 | p-valor = 0.8230
Grupo_Genero
Action              7.933019
Adventure           7.939823
Adventure+Action    7.968675
Outros              7.949067
Name: IMDB_Rating, dtype: float64
```

[ ]:
```
#separar grupos de faturamento
gross_adventure = tabela.loc[tabela['Grupo_Genero'] == 'Adventure', 'Gross']
gross_action = tabela.loc[tabela['Grupo_Genero'] == 'Action', 'Gross']
gross_both = tabela.loc[tabela['Grupo_Genero'] == 'Adventure+Action', 'Gross']
gross_outros = tabela.loc[tabela['Grupo_Genero'] == 'Outros', 'Gross']

# ANOVA para faturamento
F, p = f_oneway(gross_adventure, gross_action, gross_both, gross_outros)
print(f"ANOVA (Gross): F = {F:.3f} | p-valor = {p:.4f}")

# medias para interpretação
print(tabela.groupby('Grupo_Genero')['Gross'].mean())
```

```
ANOVA (Gross): F = 116.009 | p-valor = 0.0000
Grupo_Genero
Action              7.991307e+07
Adventure           1.142431e+08
Adventure+Action    2.195100e+08
Outros              4.080764e+07
Name: Gross, dtype: float64
```

[ ]:
```
#função para classificar gêneros
def classifica_genero_v2(row):
    genres = str(row['Genre'])
    if all(g in genres for g in ['Adventure','Action','Drama']):
        return 'Adventure+Action+Drama'
    elif 'Adventure' in genres and 'Action' in genres:
        return 'Adventure+Action'
    elif 'Adventure' in genres:
        return 'Adventure'
    elif 'Action' in genres:
        return 'Action'
    else:
        return 'Outros'

tabela['Grupo_Genero_v2'] = tabela.apply(classifica_genero_v2, axis=1)
```

```
#separar listas de notas IMDb
ratings_groups = [g['IMDB_Rating'].values
                  for _, g in tabela.groupby('Grupo_Genero_v2') if len(g) > 1]

#ANOVA
F, p = f_oneway(*ratings_groups)
print(f"ANOVA (IMDb): F = {F:.3f} | p-valor = {p:.4f}")

#medias para interpretação
print(tabela.groupby('Grupo_Genero_v2')['IMDB_Rating'].mean())
```

```
ANOVA (IMDb): F = 2.104 | p-valor = 0.0783
Grupo_Genero_v2
Action                   7.933019
Adventure                7.939823
Adventure+Action         7.931884
Adventure+Action+Drama   8.150000
Outros                   7.949067
Name: IMDB_Rating, dtype: float64
```

[ ]:
```
#separar grupos de Meta_score
meta_adventure = tabela.loc[tabela['Grupo_Genero_v2'] == 'Adventure',␣
 ↪'Meta_score']
meta_action = tabela.loc[tabela['Grupo_Genero_v2'] == 'Action', 'Meta_score']
meta_both = tabela.loc[tabela['Grupo_Genero_v2'] == 'Adventure+Action',␣
 ↪'Meta_score']
meta_both_drama = tabela.loc[tabela['Grupo_Genero_v2'] ==␣
 ↪'Adventure+Action+Drama', 'Meta_score']
meta_outros = tabela.loc[tabela['Grupo_Genero_v2'] == 'Outros', 'Meta_score']

#ANOVA para Meta_score
F, p = f_oneway(meta_adventure, meta_action, meta_both, meta_both_drama,␣
 ↪meta_outros)
print(f"ANOVA (Meta_score): F = {F:.3f} | p-valor = {p:.4f}")

#medias para interpretação
print(tabela.groupby('Grupo_Genero_v2')['Meta_score'].mean())
```

```
ANOVA (Meta_score): F = 9.266 | p-valor = 0.0000
Grupo_Genero_v2
Action                   72.621984
Adventure                79.713215
Adventure+Action         74.553496
Adventure+Action+Drama   79.958541
Outros                   78.757676
Name: Meta_score, dtype: float64
```

4.2 Filmes com maior duração (runtime) possuem maiores notas IMB.

Filmes com maior duração tendem a ter notas um pouco mais altas no imdb, mas a relação não é muito forte. ainda assim, da pra ver que produções mais longas costumam ser melhor avaliadas em média.filmes mais longos costumam ter notas um pouco melhores no imdb (r=0.243, p=0.0000) e também tendem a faturar mais (r=0.136, p=0.0000), embora as duas relações sejam fracas. isso mostra que a duração ajuda, mas não é fator decisivo pro sucesso.

[ ]:
```
plt.figure(figsize=(7,5))
sns.regplot(
    data=tabela,
    x='Runtime', y='IMDB_Rating',
    scatter_kws={'alpha':0.4}, line_kws={'color':'red'}
)
plt.title("Correlação entre Duração (Runtime) e Nota IMDB")
plt.xlabel("Duração (minutos)")
plt.ylabel("Nota IMDB")
plt.show()
```

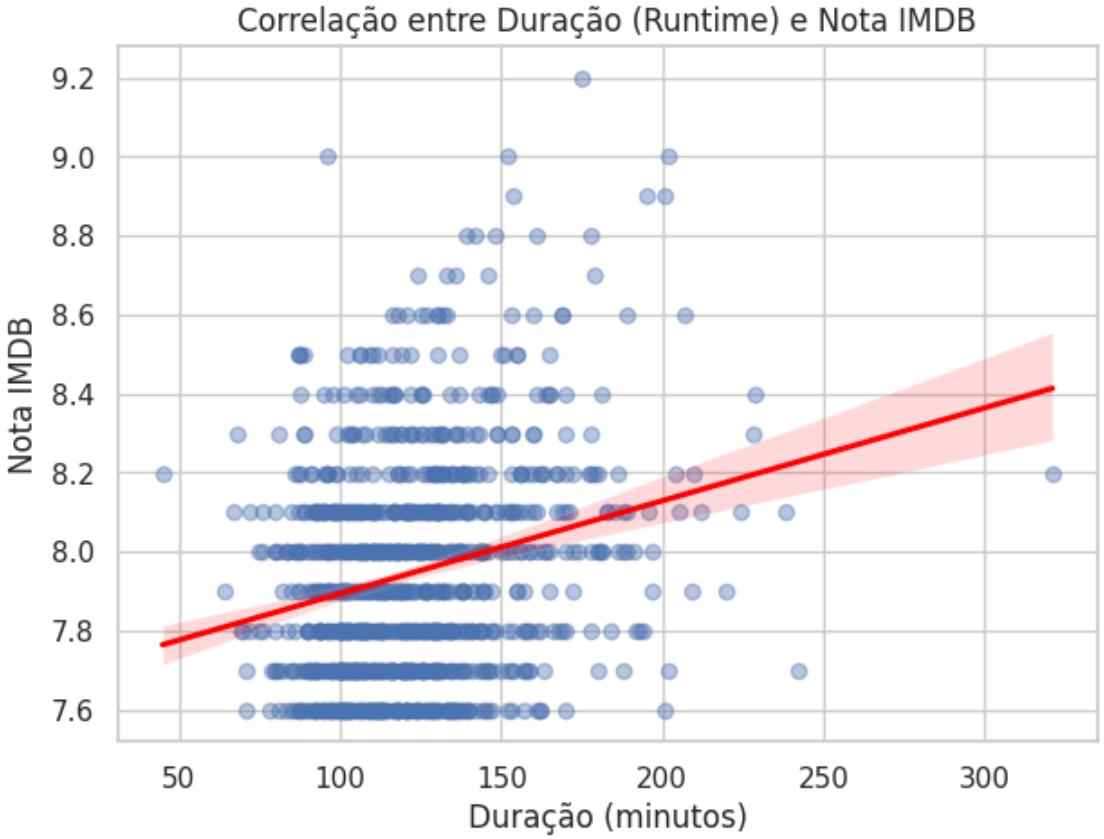

[ ]:
```
# correlação entre duração e nota
mask = tabela['Runtime'].notna() & tabela['IMDB_Rating'].notna()
```

```
r_rating, p_rating = pearsonr(tabela.loc[mask, 'Runtime'], tabela.loc[mask,␣
↪'IMDB_Rating'])
print(f"Correlação Runtime × Nota IMDB: r={r_rating:.3f}, p={p_rating:.4f}")

# correlação entre duração e faturamento
mask = tabela['Runtime'].notna() & tabela['Gross'].notna()
r_gross, p_gross = pearsonr(tabela.loc[mask, 'Runtime'], tabela.loc[mask,␣
↪'Gross'])
print(f"Correlação Runtime × Faturamento: r={r_gross:.3f}, p={p_gross:.4f}")
```

```
Correlação Runtime × Nota IMDB: r=0.243, p=0.0000
Correlação Runtime × Faturamento: r=0.136, p=0.0000
```

4.3 Combinações de atores que possuem Oscar influencia na nota? (Quanto maior for o quadro de artistas com Oscar, melhor a avaliação)

Ter mais atores vencedores do oscar no elenco não muda de forma significativa a nota do imdb. a correlação é praticamente nula ($r = 0.019$, $p = 0.55$) e a anova também confirma que não há diferença estatística entre os grupos ($p = 0.80$). na prática, filmes com ou sem grandes premiados no elenco ficam com médias muito parecidas, perto de 8.0.

[ ]:
```
#contar vencedores do Oscar no elenco
star_flags = [c for c in ['Star1_OscarActor_Winner', 'Star2_OscarActor_Winner',␣
↪'Star3_OscarActor_Winner', 'Star4_OscarActor_Winner'] if c in tabela.columns]

tabela['Cast_OscarWinners_Count'] = tabela[star_flags].sum(axis=1)

# gáficos para inspeção
plt.figure(figsize=(7,5))
sns.regplot(
    data=tabela,
    x='Cast_OscarWinners_Count', y='IMDB_Rating',
    x_jitter=0.1,
    scatter_kws={'alpha':0.4}, line_kws={'color':'red'}
)
plt.title("Atores vencedores do Oscar no elenco × Nota IMDB")
plt.xlabel("Nº de atores vencedores do Oscar no elenco")
plt.ylabel("IMDB_Rating")
plt.show()

plt.figure(figsize=(7,5))
sns.boxplot(
    data=tabela,
    x='Cast_OscarWinners_Count', y='IMDB_Rating'
)
plt.title("Nota IMDB por nº de atores vencedores do Oscar no elenco")
plt.xlabel("Nº de atores vencedores do Oscar no elenco")
```

```
plt.ylabel("IMDB_Rating")
plt.show()

#correlação de Pearson e tabela de médias por contagem
mask = tabela['Cast_OscarWinners_Count'].notna() & tabela['IMDB_Rating'].notna()
r, p = pearsonr(tabela.loc[mask, 'Cast_OscarWinners_Count'], tabela.loc[mask,␣
 ↪'IMDB_Rating'])
print(f"Correlação (Pearson): r = {r:.3f} | p-valor = {p:.4f}")

mean_by_count = (
    tabela.groupby('Cast_OscarWinners_Count', as_index=False)['IMDB_Rating']
          .mean()
          .rename(columns={'IMDB_Rating':'IMDB_Rating_mean'})
          .sort_values('Cast_OscarWinners_Count')
)
print(mean_by_count)

#ANOVA
groups = [g['IMDB_Rating'].values for _, g in tabela.
 ↪groupby('Cast_OscarWinners_Count') if len(g) > 1]
if len(groups) >= 2:
    F, p_anova = f_oneway(*groups)
    print(f"ANOVA (diferença entre grupos): F = {F:.2f} | p-valor = {p_anova:.
 ↪4f}")
```

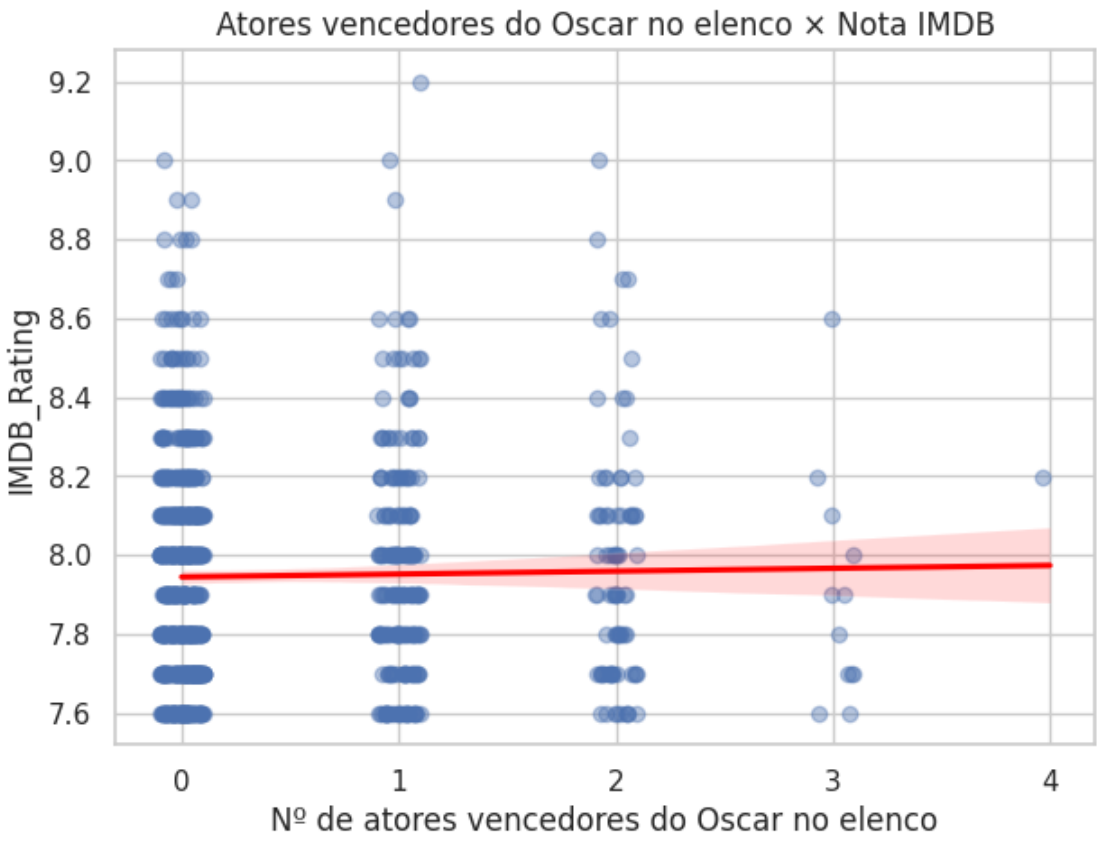
Atores vencedores do Oscar no elenco × Nota IMDB
IMDB_Rating
9.2
9.0
8.8
8.6
8.4
8.2
8.0
7.8
7.6
0
1
2
3
4
Nº de atores vencedores do Oscar no elenco

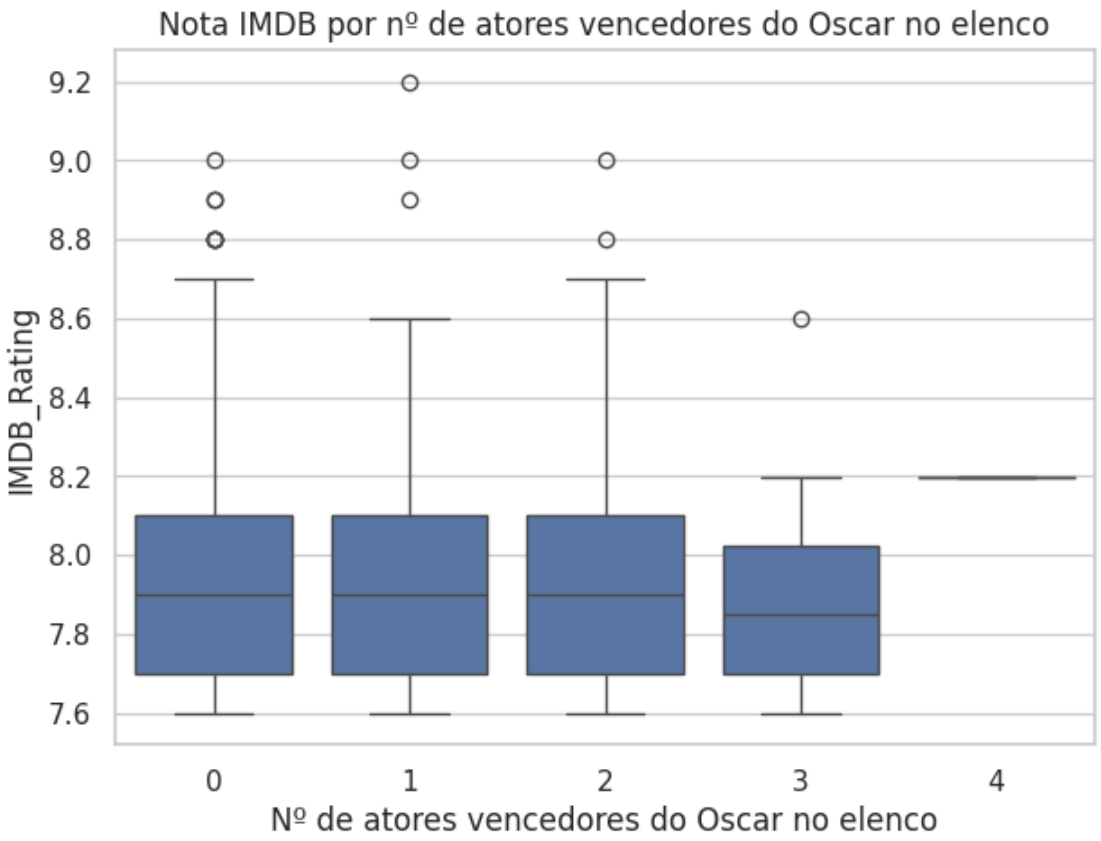


```
Correlação (Pearson): r = 0.019 | p-valor = 0.5521
   Cast_OscarWinners_Count  IMDB_Rating_mean
0                        0          7.944556
1                        1          7.953171
2                        2          7.967470
3                        3          7.900000
4                        4          8.200000
ANOVA (diferença entre grupos): F = 0.33 | p-valor = 0.8062
```

4.4 Filmes que ganharam mais oscars tem melhores notas imdb?

sim! enquanto os sem Oscar ficam perto de 7.9, os superpremiados chegam a passar de 8.2, com destaque pros que ganharam 11 Oscars (8.5 de média). Ou seja: mais Oscar costuma andar junto com mais reconhecimento do público.

[ ]:
```
#agrupar IMDb por quantidade de oscars
oscar_vs_rating = tabela.groupby('Filme_OscarCount')['IMDB_Rating'].mean()

print("Média da nota IMDb por quantidade de Oscars:")
print(oscar_vs_rating)
```

```
#boxplot para ver distribuição
plt.figure(figsize=(8,5))
sns.boxplot(x='Filme_OscarCount', y='IMDB_Rating', data=tabela, palette="Blues")
plt.title("Notas IMDb por quantidade de Oscars ganhos")
plt.xlabel("Quantidade de Oscars ganhos")
plt.ylabel("IMDb Rating")
plt.show()
```

```
Média da nota IMDb por quantidade de Oscars:
Filme_OscarCount
0     7.925377
1     7.934694
2     8.007018
3     8.027027
4     8.048485
5     8.166667
6     8.133333
7     8.225000
8     7.950000
9     7.900000
11    8.500000
12    7.800000
Name: IMDB_Rating, dtype: float64
/tmp/ipykernel_9964/903175745.py:9: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in
v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same
effect.

  sns.boxplot(x='Filme_OscarCount', y='IMDB_Rating', data=tabela,
palette="Blues")
```

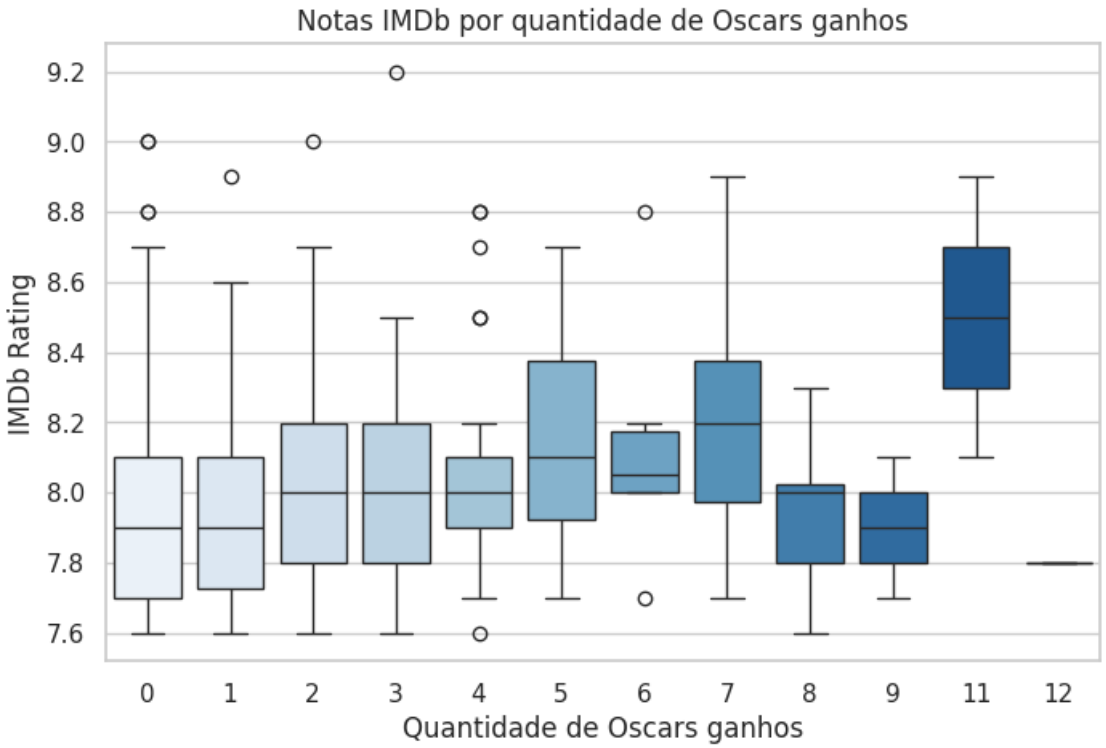

5 Perguntas

5.1 a - Qual filme você recomendaria para uma pessoa que você não conhece?

O filme que eu indicaria é o "**the dark knight**". Apesar de ele ter um IMDb menor em 0.2 pontos que o "the godfather", quando comparamos o no_of_votes vemos que "tha dark knight"tem maior número. Para poder rankear foi realizada uma multiplicação entre o IMDb e o Log do No_of_votes e assim, podemos perceber que em ranking o "**the dark knight**' está melhor colocado. Outro fator importante é a classificação indicativa, se a pessoa é desconhecida eu não sei a idade dela, então um filme com UA de classificação é mais"leve" que um filme A (corresponderia ao +18 no Brasil).

[ ]:
```
#criar uma metrica de ranking
# aqui pego a nota e multiplico pelo log do numero de votos

tabela["Ranking_Score"] = tabela["IMDB_Rating"] * np.
 ↪log1p(tabela["No_of_Votes"])

#ordenar pela metrica
top_filmes = tabela.sort_values(by="Ranking_Score", ascending=False).head(10)

print(top_filmes[["Series_Title", "IMDB_Rating", "No_of_Votes",␣
 ↪"Ranking_Score", "Certificate"]])
```

```
                                        Series_Title  IMDB_Rating
1                                    the dark knight          9.0  \
0                                      the godfather          9.2
5                                       pulp fiction          8.9
7                                          inception          8.8
4       the lord of the rings: the return of the king          8.9
8                                        fight club          8.8
10                                      forrest gump          8.8
9    the lord of the rings: the fellowship of the ring          8.8
2                               the godfather: part ii          9.0
13                                         the matrix          8.7

    No_of_Votes  Ranking_Score Certificate
1       2303232     131.848419          UA
0       1620367     131.543107           A
5       1826188     128.317902           A
7       2067042     127.966341          UA
4       1642758     127.375801           U
8       1854740     127.012649           A
10      1809221     126.793986          UA
9       1661481     126.044341           U
2       1129952     125.439179           A
13      1676426     124.689925           A
```

5.2 b - Quais são os principais fatores que estão relacionados com alta expectativa de faturamento de um filme?

O faturamento se mostra mais associado a gêneros de apelo comercial como aventura, ação e ficção científica, além de ganhar impulso com filmes mais longos e lançados mais recentemente. Em contrapartida, dramas e romances tendem a reduzir o potencial de bilheteria.

[ ]:
```
y = pd.to_numeric(tabela['Gross'], errors='coerce')

from scipy.stats import spearmanr
features = {}
features['Released_Year'] = pd.to_datetime(tabela['Released_Year'],␣
 ↪errors='coerce').dt.year
features['Runtime'] = pd.to_numeric(tabela['Runtime'].astype(str).str.
 ↪extract(r'(\d+)')[0], errors='coerce')

genero_cols = [
   ␣
 ↪"Action","Adventure","Animation","Biography","Comedy","Crime","Drama","Family",
   ␣
 ↪"Fantasy","Film-Noir","History","Horror","Music","Musical","Mystery","Romance",
    "Sci-Fi","Sport","Thriller","War","Western"
]
```

```
for c in genero_cols:
    if c in tabela.columns:
        features[c] = pd.to_numeric(tabela[c], errors='coerce')

corr = {}
for name, col in features.items():
    r, _ = spearmanr(col, y, nan_policy='omit')
    corr[name] = r

for k, v in sorted(corr.items(), key=lambda kv: abs(kv[1]), reverse=True)[:15]:
    print(f"{k}: {v:.4f}")
```

```
Adventure: 0.3447
Action: 0.2827
Drama: -0.2407
Runtime: 0.1474
Released_Year: 0.1417
Sci-Fi: 0.1365
Romance: -0.1307
Animation: 0.1213
Music: -0.0866
Biography: 0.0762
Mystery: -0.0748
Crime: -0.0737
Film-Noir: -0.0724
Musical: -0.0601
Family: 0.0592
```

5.3 c- Quais insights podem ser tirados com a coluna Overview? É possível inferir o gênero do filme a partir dessa coluna?

A coluna overview traz o resumo dos filmes, então a partir dela é possível identificar quais palavras aparecem com mais frequência ex.: love, family, war, life. isso já dá uma ideia dos temas mais recorrentes no cinema. Então eu usei a coluna overview e transformei esses textos em números com a técnica chamada TF-IDF, que basicamente que conta as palavras mais importantes e tira as que se repetem demais. Depois, treinei um modelo de regressão logística usando a estratégia one-vs-rest ou seja, ele cria um classificador pra cada genero, tipo um so pra action, outro so pra drama, outro so pra comedy e assim por diante. isso permite que um mesmo filme receba mais de um gênero. Nos testes, o modelo alcançou em torno de f1 micro = 0,48 e f1 macro = 0,14. em outras palavras, ele consegue acertar os gêneros mais comuns, mas tem bastante dificuldade nos gêneros mais raros, porque quase não tem exemplos deles no dataset.então, **sim, o overview pode ajudar a prever o gênero do filme**, mas sozinho não é suficiente. funciona razoavelmente bem para gêneros muito frequentes, mas para melhorar o resultado em geral seria preciso equilibrar melhor os dados ou incluir outras informações (como ano de lançamento, número de votos ou avaliações). Além disso, o gráfico de bolhas mostra de forma visual quais palavras e combinações se repetem em muitos filmes e como elas se relacionam com a nota média no IMDb.

[ ]:
```
# Contar palavras mais comuns nos overviews
cv = CountVectorizer(stop_words="english", max_features=20)
X_counts = cv.fit_transform(tabela["Overview"].fillna(""))

word_freq = pd.DataFrame({
    "word": cv.get_feature_names_out(),
    "freq": X_counts.toarray().sum(axis=0)
}).sort_values(by="freq", ascending=False)

print(word_freq)
```

```
        word  freq
19     young   132
10       man   119
8       life   111
17     world    85
11       new    73
14       war    66
2     family    66
16     woman    65
13     story    63
9       love    61
12       old    54
4      finds    47
1        boy    46
7       help    45
3     father    45
15      wife    44
6       girl    42
0   american    40
5    friends    39
18      year    39
```

[ ]:
```
from sklearn.naive_bayes import MultinomialNB

# Dados
X_text = tabela["Overview"].fillna("")
y = tabela[genero_cols]

# TF-IDF
tfidf = TfidfVectorizer(stop_words="english", max_features=10000,␣
 ↪ngram_range=(1,2))
X_tfidf = tfidf.fit_transform(X_text)

# Split
X_train, X_test, y_train, y_test = train_test_split(X_tfidf, y, test_size=0.2,␣
 ↪random_state=42)
```

```python
# Modelos
modelos = {
    "LogisticRegression": OneVsRestClassifier(LogisticRegression(max_iter=300,␣
 ↪class_weight="balanced", n_jobs=-1)),
    "NaiveBayes": OneVsRestClassifier(MultinomialNB()),
    "RandomForest":␣
 ↪OneVsRestClassifier(RandomForestClassifier(n_estimators=300, max_depth=15,␣
 ↪n_jobs=-1, random_state=42))
}

# Avaliação
for nome, modelo in modelos.items():
    print(f"\n {nome}")
    modelo.fit(X_train, y_train)
    y_pred = modelo.predict(X_test)
    print(f"F1 micro: {f1_score(y_test, y_pred, average='micro'):.4f}")
    print(f"F1 macro: {f1_score(y_test, y_pred, average='macro'):.4f}")
    print(classification_report(y_test, y_pred, zero_division=0))
```

```
 LogisticRegression
F1 micro: 0.4839
F1 macro: 0.1400
              precision    recall  f1-score   support

           0       0.50      0.12      0.19        34
           1       0.71      0.12      0.21        40
           2       0.50      0.06      0.10        18
           3       0.60      0.12      0.20        25
           4       0.54      0.15      0.24        46
           5       0.54      0.16      0.25        43
           6       0.82      0.93      0.87       157
           7       0.00      0.00      0.00         5
           8       0.00      0.00      0.00         9
           9       0.00      0.00      0.00         3
          10       0.00      0.00      0.00         8
          11       0.00      0.00      0.00        10
          12       0.00      0.00      0.00         9
          13       0.00      0.00      0.00         4
          14       1.00      0.09      0.16        23
          15       0.50      0.05      0.09        21
          16       1.00      0.09      0.17        11
          17       0.00      0.00      0.00         3
          18       0.00      0.00      0.00        25
          19       0.60      0.38      0.46         8
          20       0.00      0.00      0.00         3
```

```
   micro avg       0.75      0.36      0.48       505
   macro avg       0.35      0.11      0.14       505
weighted avg       0.59      0.36      0.38       505
 samples avg       0.73      0.41      0.50       505


 NaiveBayes
F1 micro: 0.4454
F1 macro: 0.0419
              precision    recall  f1-score   support

           0       0.00      0.00      0.00        34
           1       0.00      0.00      0.00        40
           2       0.00      0.00      0.00        18
           3       0.00      0.00      0.00        25
           4       0.00      0.00      0.00        46
           5       0.00      0.00      0.00        43
           6       0.79      1.00      0.88       157
           7       0.00      0.00      0.00         5
           8       0.00      0.00      0.00         9
           9       0.00      0.00      0.00         3
          10       0.00      0.00      0.00         8
          11       0.00      0.00      0.00        10
          12       0.00      0.00      0.00         9
          13       0.00      0.00      0.00         4
          14       0.00      0.00      0.00        23
          15       0.00      0.00      0.00        21
          16       0.00      0.00      0.00        11
          17       0.00      0.00      0.00         3
          18       0.00      0.00      0.00        25
          19       0.00      0.00      0.00         8
          20       0.00      0.00      0.00         3

   micro avg       0.79      0.31      0.45       505
   macro avg       0.04      0.05      0.04       505
weighted avg       0.24      0.31      0.27       505
 samples avg       0.79      0.37      0.48       505


 RandomForest
F1 micro: 0.4454
F1 macro: 0.0419
              precision    recall  f1-score   support

           0       0.00      0.00      0.00        34
           1       0.00      0.00      0.00        40
           2       0.00      0.00      0.00        18
```

```
              3       0.00      0.00      0.00        25
              4       0.00      0.00      0.00        46
              5       0.00      0.00      0.00        43
              6       0.79      1.00      0.88       157
              7       0.00      0.00      0.00         5
              8       0.00      0.00      0.00         9
              9       0.00      0.00      0.00         3
             10       0.00      0.00      0.00         8
             11       0.00      0.00      0.00        10
             12       0.00      0.00      0.00         9
             13       0.00      0.00      0.00         4
             14       0.00      0.00      0.00        23
             15       0.00      0.00      0.00        21
             16       0.00      0.00      0.00        11
             17       0.00      0.00      0.00         3
             18       0.00      0.00      0.00        25
             19       0.00      0.00      0.00         8
             20       0.00      0.00      0.00         3

   micro avg       0.79      0.31      0.45       505
   macro avg       0.04      0.05      0.04       505
weighted avg       0.24      0.31      0.27       505
 samples avg       0.79      0.37      0.48       505
```

[ ]:
```python
# usar apenas bigramas
cv_bi = CountVectorizer(stop_words="english", ngram_range=(2,2), min_df=2,␣
 ↪max_features=5000)
X_bi = cv_bi.fit_transform(tabela["Overview"].fillna(""))

termos_bi = np.array(cv_bi.get_feature_names_out())
freq_total_bi = np.asarray(X_bi.sum(axis=0)).ravel()
n_filmes_bi = np.asarray((X_bi > 0).sum(axis=0)).ravel()

# calcular média de votos por bigrama
votos = tabela["No_of_Votes"].values
rows, cols = X_bi.nonzero()
soma_votos = np.zeros_like(n_filmes_bi, dtype=float)
for r, c in zip(rows, cols):
    soma_votos[c] += votos[r]
votos_medio_bi = np.where(n_filmes_bi > 0, soma_votos / n_filmes_bi, np.nan)

df_bi["votos_medio"] = votos_medio_bi

# pegar top bigramas
df_top = df_bi.sort_values(["n_filmes","freq"], ascending=False).head(10)
```

```
# gráfico de bolhas usando votos como tamanho
plt.figure(figsize=(12,7))
plt.scatter(df_top["imdb_medio"], df_top["n_filmes"],
            s=df_top["votos_medio"] / 50,   # divisor controla escala
            alpha=0.35)

for _, row in df_top.iterrows():
    plt.text(row["imdb_medio"], row["n_filmes"], row["termo"], fontsize=8)

plt.xlabel("Média IMDb")
plt.ylabel("Quantidade de Filmes")
plt.title("Combinações de palavras (bigramas) no Overview")
plt.grid(alpha=0.2)
plt.show()
```

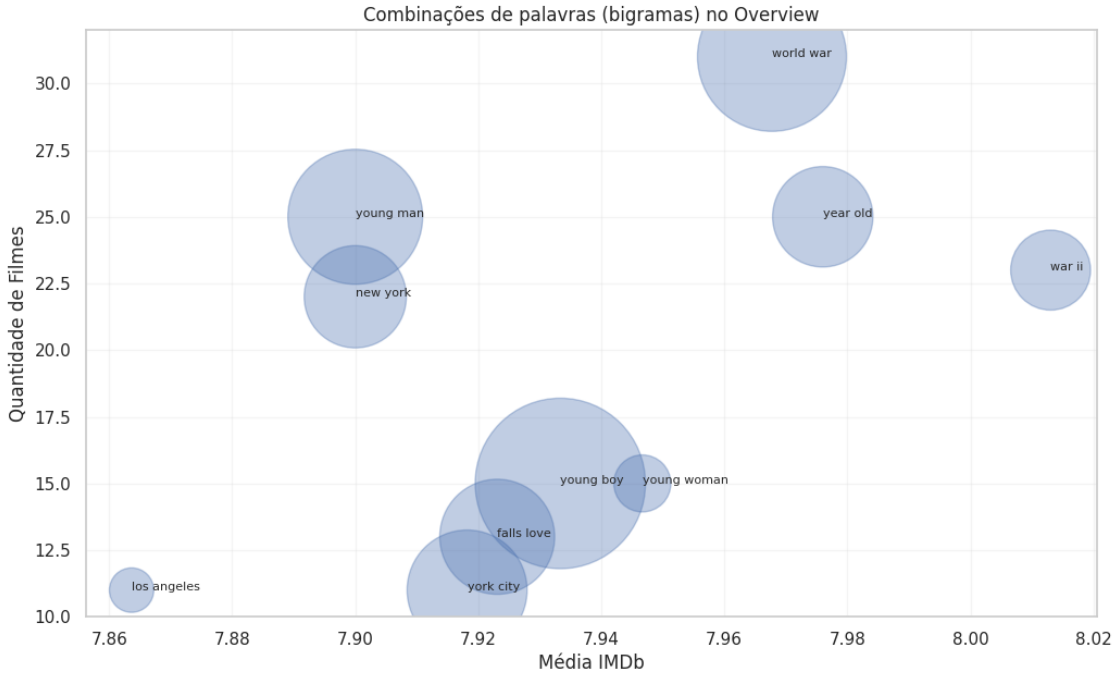

6 Explicações

Explique como você faria a previsão da nota do imdb a partir dos dados. Quais variáveis e/ou suas transformações você utilizou e por quê? Qual tipo de problema estamos resolvendo (regressão, classificação)? Qual modelo melhor se aproxima dos dados e quais seus prós e contras? Qual medida de performance do modelo foi escolhida e por quê?

Após treinar diferentes modelos, o que apresentou melhor desempenho foi o XGBoost Regressor, alcançando R^2 de 52,7% e RMSE de 0,191. Esse modelo superou tanto a Regressão Linear Múltipla (R^2 31,3%) quanto o Random Forest (R^2 43,8%). As variáveis utilizadas incluíram

popularidade (No_of_Votes), avaliação crítica (Meta_score), características de produção (Runtime, Budget_USD, Gross ou Profit), idioma original e gênero (convertidos em dummies), além de indicadores de premiação de atores/diretor e TF-IDF de palavras-chave (Keywords). Essas transformações foram importantes para capturar informações de diferentes naturezas: numéricas, categóricas e textuais. Por se tratar de um problema de regressão supervisionada, em que a variável alvo (IMDB_Rating) é contínua, optamos por modelos regressivos. Para medir a performance, utilizamos R^2, que mostra a proporção da variância explicada pelo modelo, complementado por RMSE e MAE, que avaliam a precisão média das previsões.

6.0.1 Regressão Linear

[ ]:
```
#features escolhidas
X = pd.concat([
    tabela[["Meta_score","No_of_Votes","Runtime"]],
    tabela[genero_cols],
    tabela[idioma_cols]
], axis=1)

#target
y = tabela["IMDB_Rating"]

#split treino/teste
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3,␣
 ↪random_state=42)

#modelo
modelo = LinearRegression()
modelo.fit(X_train, y_train)

#predicao
y_pred = modelo.predict(X_test)

#avaliacao
print("R²:", r2_score(y_test, y_pred))
print("RMSE:", np.sqrt(mean_squared_error(y_test, y_pred)))
print("MAE:", mean_absolute_error(y_test, y_pred))

#coeficientes
coef = pd.DataFrame({
    "Variavel": X.columns,
    "Coeficiente": modelo.coef_
}).sort_values(by="Coeficiente", key=abs, ascending=False)

print("\nCoeficientes mais importantes:")
print(coef.head(15))
```

```
R²: 0.3928767995405563
RMSE: 0.216852633791368
```

```
MAE: 0.1707161398652562

Coeficientes mais importantes:
     Variavel  Coeficiente
49    lang_ta     0.313400
42    lang_nl    -0.306871
38    lang_kn     0.249274
28    lang_en    -0.240845
44    lang_ro    -0.239619
33    lang_ga    -0.234491
24    lang_bs    -0.221242
29    lang_es    -0.161660
26    lang_da    -0.159891
52    lang_uz    -0.158444
32    lang_fr    -0.154346
50    lang_te     0.118095
25    lang_cn    -0.108778
51    lang_tr     0.108020
12  Film-Noir     0.106463
```

6.0.2 Random Forest Regressor

[ ]:
```
#selecionar features
X_reduced = tabela[['No_of_Votes', 'Meta_score', 'Budget_USD', 'Runtime',␣
 ↪'Gross', 'Released_Year']]
X_reduced = X_reduced.apply(pd.to_numeric, errors='coerce').fillna(0)
y = tabela['IMDB_Rating']

#treino/teste
X_train, X_test, y_train, y_test = train_test_split(X_reduced, y, test_size=0.
 ↪3, random_state=42)

#random Forest
forest = RandomForestRegressor(random_state=42, n_estimators=300, max_depth=15,␣
 ↪min_samples_leaf=2, n_jobs=-1)
forest.fit(X_train, y_train)
y_pred = forest.predict(X_test)

#métricas
r2  = r2_score(y_test, y_pred)
rmse = np.sqrt(mean_squared_error(y_test, y_pred))
mae  = mean_absolute_error(y_test, y_pred)

print("Random Forest")
print("R²:", r2, f"({r2*100:.2f}%)")
print("RMSE:", rmse)
print("MAE:", mae)
```

```
Random Forest
R²: 0.5341157167404244 (53.41%)
RMSE: 0.189961380244702
MAE: 0.14969101086242445
```

6.0.3 XGBoost

[ ]:
```python
# features
X_reduced = tabela[['No_of_Votes', 'Meta_score', 'Budget_USD', 'Runtime',␣
 ↪'Gross', 'Released_Year']]
X_reduced = X_reduced.apply(pd.to_numeric, errors='coerce').fillna(0)
y = tabela['IMDB_Rating']

# split
X_train, X_test, y_train, y_test = train_test_split(X_reduced, y, test_size=0.
 ↪3, random_state=42)

# modelo base
xgb = XGBRegressor(random_state=42, n_jobs=-1)

# espaço de busca
param_dist = {
    "n_estimators": [200, 300, 500, 800],
    "learning_rate": [0.01, 0.05, 0.1, 0.2],
    "max_depth": [3, 5, 6, 8, 10],
    "subsample": [0.6, 0.8, 1.0],
    "colsample_bytree": [0.6, 0.8, 1.0],
    "min_child_weight": [1, 3, 5, 7]
}

# random search
random_search = RandomizedSearchCV(
    estimator=xgb,
    param_distributions=param_dist,
    n_iter=20,          # número de combinações testadas (pode aumentar se␣
 ↪quiser)
    scoring="r2",
    cv=3,
    verbose=2,
    random_state=42,
    n_jobs=-1
)

# treino
random_search.fit(X_train, y_train)

# melhor modelo
```

```python
best_xgb = random_search.best_estimator_
print("Melhores parâmetros:", random_search.best_params_)

# avaliar no teste
y_pred = best_xgb.predict(X_test)
r2  = r2_score(y_test, y_pred)
rmse = np.sqrt(mean_squared_error(y_test, y_pred))
mae  = mean_absolute_error(y_test, y_pred)

print("\nXGBoost Regressor - RandomizedSearch Otimizado")
print("R²:", r2, f"({r2*100:.2f}%)")
print("RMSE:", rmse)
print("MAE:", mae)
```

```
Fitting 3 folds for each of 20 candidates, totalling 60 fits
[CV] END colsample_bytree=0.8, learning_rate=0.01, max_depth=6,
min_child_weight=7, n_estimators=300, subsample=0.6; total time=   0.3s
[CV] END colsample_bytree=0.8, learning_rate=0.01, max_depth=6,
min_child_weight=7, n_estimators=300, subsample=0.6; total time=   0.3s
[CV] END colsample_bytree=0.8, learning_rate=0.01, max_depth=8,
min_child_weight=5, n_estimators=200, subsample=1.0; total time=   0.3s
[CV] END colsample_bytree=0.6, learning_rate=0.2, max_depth=6,
min_child_weight=7, n_estimators=500, subsample=1.0; total time=   0.3s
[CV] END colsample_bytree=0.8, learning_rate=0.01, max_depth=6,
min_child_weight=7, n_estimators=300, subsample=0.6; total time=   0.4s
[CV] END colsample_bytree=0.6, learning_rate=0.2, max_depth=6,
min_child_weight=7, n_estimators=500, subsample=1.0; total time=   0.4s
[CV] END colsample_bytree=0.8, learning_rate=0.01, max_depth=8,
min_child_weight=5, n_estimators=200, subsample=1.0; total time=   0.4s
[CV] END colsample_bytree=0.8, learning_rate=0.05, max_depth=5,
min_child_weight=7, n_estimators=800, subsample=0.8; total time=   0.5s
[CV] END colsample_bytree=0.6, learning_rate=0.2, max_depth=6,
min_child_weight=7, n_estimators=500, subsample=1.0; total time=   0.5s
[CV] END colsample_bytree=0.8, learning_rate=0.01, max_depth=8,
min_child_weight=5, n_estimators=200, subsample=1.0; total time=   0.6s
[CV] END colsample_bytree=0.8, learning_rate=0.05, max_depth=3,
min_child_weight=7, n_estimators=200, subsample=1.0; total time=   0.1s
[CV] END colsample_bytree=1.0, learning_rate=0.05, max_depth=3,
min_child_weight=1, n_estimators=800, subsample=0.6; total time=   0.3s
[CV] END colsample_bytree=0.8, learning_rate=0.05, max_depth=5,
min_child_weight=7, n_estimators=800, subsample=0.8; total time=   0.7s
[CV] END colsample_bytree=0.8, learning_rate=0.05, max_depth=5,
min_child_weight=7, n_estimators=800, subsample=0.8; total time=   0.7s
[CV] END colsample_bytree=0.8, learning_rate=0.05, max_depth=3,
min_child_weight=7, n_estimators=200, subsample=1.0; total time=   0.1s
[CV] END colsample_bytree=0.8, learning_rate=0.05, max_depth=3,
min_child_weight=7, n_estimators=200, subsample=1.0; total time=   0.1s
```

```
[CV] END colsample_bytree=1.0, learning_rate=0.05, max_depth=3,
min_child_weight=1, n_estimators=800, subsample=0.6; total time=   0.4s
[CV] END colsample_bytree=1.0, learning_rate=0.05, max_depth=3,
min_child_weight=1, n_estimators=800, subsample=0.6; total time=   0.5s
[CV] END colsample_bytree=0.8, learning_rate=0.1, max_depth=3,
min_child_weight=7, n_estimators=500, subsample=0.6; total time=   0.2s
[CV] END colsample_bytree=0.6, learning_rate=0.05, max_depth=5,
min_child_weight=7, n_estimators=500, subsample=0.6; total time=   0.3s
[CV] END colsample_bytree=0.8, learning_rate=0.1, max_depth=3,
min_child_weight=7, n_estimators=500, subsample=0.6; total time=   0.2s
[CV] END colsample_bytree=0.6, learning_rate=0.05, max_depth=5,
min_child_weight=7, n_estimators=500, subsample=0.6; total time=   0.3s
[CV] END colsample_bytree=0.8, learning_rate=0.1, max_depth=10,
min_child_weight=1, n_estimators=500, subsample=0.6; total time=   0.8s
[CV] END colsample_bytree=0.6, learning_rate=0.05, max_depth=5,
min_child_weight=7, n_estimators=500, subsample=0.6; total time=   0.4s
[CV] END colsample_bytree=0.8, learning_rate=0.1, max_depth=10,
min_child_weight=1, n_estimators=500, subsample=0.6; total time=   0.9s
[CV] END colsample_bytree=0.8, learning_rate=0.1, max_depth=3,
min_child_weight=7, n_estimators=500, subsample=0.6; total time=   0.3s
[CV] END colsample_bytree=0.8, learning_rate=0.2, max_depth=3,
min_child_weight=1, n_estimators=300, subsample=1.0; total time=   0.1s
[CV] END colsample_bytree=0.8, learning_rate=0.1, max_depth=10,
min_child_weight=1, n_estimators=500, subsample=0.6; total time=   1.0s
[CV] END colsample_bytree=0.8, learning_rate=0.2, max_depth=3,
min_child_weight=1, n_estimators=300, subsample=1.0; total time=   0.2s
[CV] END colsample_bytree=0.8, learning_rate=0.2, max_depth=3,
min_child_weight=1, n_estimators=300, subsample=1.0; total time=   0.2s
[CV] END colsample_bytree=0.6, learning_rate=0.2, max_depth=5,
min_child_weight=1, n_estimators=200, subsample=0.8; total time=   0.2s
[CV] END colsample_bytree=0.6, learning_rate=0.2, max_depth=5,
min_child_weight=1, n_estimators=200, subsample=0.8; total time=   0.3s
[CV] END colsample_bytree=0.6, learning_rate=0.2, max_depth=5,
min_child_weight=1, n_estimators=200, subsample=0.8; total time=   0.3s
[CV] END colsample_bytree=0.6, learning_rate=0.05, max_depth=10,
min_child_weight=5, n_estimators=800, subsample=0.8; total time=   1.4s
[CV] END colsample_bytree=0.6, learning_rate=0.05, max_depth=10,
min_child_weight=5, n_estimators=800, subsample=0.8; total time=   1.5s
[CV] END colsample_bytree=0.6, learning_rate=0.05, max_depth=10,
min_child_weight=5, n_estimators=800, subsample=0.8; total time=   1.5s
[CV] END colsample_bytree=0.6, learning_rate=0.01, max_depth=6,
min_child_weight=5, n_estimators=800, subsample=0.8; total time=   0.9s
[CV] END colsample_bytree=0.6, learning_rate=0.01, max_depth=6,
min_child_weight=5, n_estimators=800, subsample=0.8; total time=   1.0s
[CV] END colsample_bytree=0.8, learning_rate=0.1, max_depth=5,
min_child_weight=5, n_estimators=300, subsample=0.6; total time=   0.3s
[CV] END colsample_bytree=0.8, learning_rate=0.1, max_depth=5,
min_child_weight=5, n_estimators=300, subsample=0.6; total time=   0.2s
```

```
[CV] END colsample_bytree=1.0, learning_rate=0.05, max_depth=10,
min_child_weight=7, n_estimators=300, subsample=0.6; total time=   0.6s
[CV] END colsample_bytree=1.0, learning_rate=0.05, max_depth=10,
min_child_weight=7, n_estimators=300, subsample=0.6; total time=   0.5s
[CV] END colsample_bytree=0.6, learning_rate=0.01, max_depth=6,
min_child_weight=5, n_estimators=800, subsample=0.8; total time=   1.1s
[CV] END colsample_bytree=0.8, learning_rate=0.1, max_depth=5,
min_child_weight=5, n_estimators=300, subsample=0.6; total time=   0.3s
[CV] END colsample_bytree=1.0, learning_rate=0.05, max_depth=10,
min_child_weight=7, n_estimators=300, subsample=0.6; total time=   0.6s
[CV] END colsample_bytree=0.8, learning_rate=0.05, max_depth=3,
min_child_weight=3, n_estimators=300, subsample=0.6; total time=   0.2s
[CV] END colsample_bytree=0.8, learning_rate=0.05, max_depth=3,
min_child_weight=3, n_estimators=300, subsample=0.6; total time=   0.1s
[CV] END colsample_bytree=0.8, learning_rate=0.05, max_depth=3,
min_child_weight=3, n_estimators=300, subsample=0.6; total time=   0.1s
[CV] END colsample_bytree=1.0, learning_rate=0.1, max_depth=3,
min_child_weight=5, n_estimators=800, subsample=0.6; total time=   0.4s
[CV] END colsample_bytree=1.0, learning_rate=0.1, max_depth=3,
min_child_weight=5, n_estimators=800, subsample=0.6; total time=   0.4s[CV] END
colsample_bytree=1.0, learning_rate=0.2, max_depth=10, min_child_weight=3,
n_estimators=800, subsample=0.6; total time=   0.5s

[CV] END colsample_bytree=1.0, learning_rate=0.2, max_depth=10,
min_child_weight=3, n_estimators=800, subsample=0.6; total time=   0.6s
[CV] END colsample_bytree=1.0, learning_rate=0.1, max_depth=3,
min_child_weight=5, n_estimators=800, subsample=0.6; total time=   0.6s
[CV] END colsample_bytree=1.0, learning_rate=0.2, max_depth=10,
min_child_weight=3, n_estimators=800, subsample=0.6; total time=   0.6s
[CV] END colsample_bytree=0.6, learning_rate=0.2, max_depth=10,
min_child_weight=7, n_estimators=500, subsample=0.8; total time=   0.4s
[CV] END colsample_bytree=0.6, learning_rate=0.2, max_depth=10,
min_child_weight=7, n_estimators=500, subsample=0.8; total time=   0.4s
[CV] END colsample_bytree=0.6, learning_rate=0.2, max_depth=10,
min_child_weight=7, n_estimators=500, subsample=0.8; total time=   0.4s
[CV] END colsample_bytree=1.0, learning_rate=0.01, max_depth=10,
min_child_weight=3, n_estimators=800, subsample=1.0; total time=   1.8s
[CV] END colsample_bytree=1.0, learning_rate=0.01, max_depth=10,
min_child_weight=3, n_estimators=800, subsample=1.0; total time=   1.9s
[CV] END colsample_bytree=1.0, learning_rate=0.01, max_depth=10,
min_child_weight=3, n_estimators=800, subsample=1.0; total time=   1.9s
Melhores parâmetros: {'subsample': 1.0, 'n_estimators': 200, 'min_child_weight':
7, 'max_depth': 3, 'learning_rate': 0.05, 'colsample_bytree': 0.8}

XGBoost Regressor - RandomizedSearch Otimizado
R²: 0.5272271235752825 (52.72%)
RMSE: 0.19136061714750643
MAE: 0.15367420482635497
```

[ ]:
```
import joblib
joblib.dump(best_xgb, "model.pkl")
```

[ ]:
```
['model.pkl']
```

7 Suposição de filme com características específicas:

Supondo um filme com as seguintes características:

{‘Series_Title’: ‘The Shawshank Redemption’, ‘Released_Year’: ‘1994’, ‘Certificate’: ‘A’, ‘Runtime’: ‘142 min’, ‘Genre’: ‘Drama’, ‘Overview’: ‘Two imprisoned men bond over a number of years, finding solace and eventual redemption through acts of common decency.’, ‘Meta_score’: 80.0, ‘Director’: ‘Frank Darabont’, ‘Star1’: ‘Tim Robbins’, ‘Star2’: ‘Morgan Freeman’, ‘Star3’: ‘Bob Gunton’, ‘Star4’: ‘William Sadler’, ‘No_of_Votes’: 2343110, ‘Gross’: ‘28,341,469’}

Qual seria a nota do IMDB?

[ ]:
```
#dicionário do novo filme
filme_dict = {
    'Series_Title': 'The Shawshank Redemption',
    'Released_Year': 1994,
    'Certificate': 'A',
    'Runtime': 142,
    'Genre': 'Drama',
    'Meta_score': 80.0,
    'Director': 'Frank Darabont',
    'Star1': 'Tim Robbins',
    'Star2': 'Morgan Freeman',
    'Star3': 'Bob Gunton',
    'Star4': 'William Sadler',
    'No_of_Votes': 2343110,
    'Gross': 28341469,
    'Budget_USD': 25000000  ##Esse foi adicionado externamente/manualmente.
}

#criar DataFrame com as colunas usadas no treino
novo_filme = pd.DataFrame([{
    'No_of_Votes': filme_dict['No_of_Votes'],
    'Meta_score': filme_dict['Meta_score'],
    'Budget_USD': filme_dict['Budget_USD'],
    'Runtime': filme_dict['Runtime'],
    'Gross': filme_dict['Gross'],
    'Released_Year': filme_dict['Released_Year']
}])

#fazer a previsão
pred_nota = best_xgb.predict(novo_filme)
print("Nota prevista do IMDB:", round(pred_nota[0], 2))
```

```
Nota prevista do IMDB: 8.85
```

7.0.1 Teste com o pkl aqui

coloquei apenas as informações do filme que utilizei para o modelo

[ ]:
```python
import joblib

# carregar o modelo salvo
modelo = joblib.load("model.pkl")

# dicionário do Shawshank
filme_dict = {
    'No_of_Votes': 2343110,
    'Meta_score': 80.0,
    'Budget_USD': 25000000,
    'Runtime': 142,
    'Gross': 28341469,
    'Released_Year': 1994
}

novo_filme = pd.DataFrame([filme_dict])

# prever
pred = modelo.predict(novo_filme)
print("Nota prevista do IMDb:", round(pred[0], 2))
```

```
Nota prevista do IMDb: 8.85
```

8 Adendo

ao analisar os graficos temporais percebemos que tem diferenca grande no comportamento dos dados nas epocas antes de 1990. os dados parecem de outro cenario, tentei usar log achando que ia melhorar, a distribuicao ficou mais normal, mas no modelo piorou, entao tirei o log e voltei pro bruto. pra nao cortar os filmes antigos usei o proprio released_year como ano e criei year_centered que é o ano menos 1990, fiz um flag pre1990 pra marcar os mais antigos, tambem criei interacoes do tipo variavel x pre1990 pra deixar o modelo aprender efeitos diferentes antes e depois. marquei quando o meta_score esta faltando porque nos filmes antigos isso acontece mais, generos ficaram multi hot mesmo sem tirar coluna porque um filme pode ter mais de um genero e se tirar perde informacao, nos idiomas usei dummies com drop_first porque aqui deu um pouco melhor. no split estratifiquei por faixas de ano pra treino e teste ficarem parecidos, usei pesos por era pra nao deixar o pos 1990 pesar demais, testei tf idf nas keywords mas trouxe ruido e o r2 caiu, entao tirei. no final deixei o random forest com essas features de epoca, ficou mais equilibrado entre as epocas e o r2 geral ficou ok sem precisar remover os filmes antigos. mesmo com essas alteracoes o modelo nao superou a melhor alternativa, vamos manter o xgboost (que fizemos nas sessões acima) como preditor principal. Pro futuro vale testar uma rede neural ou buscar outras fontes de dados que complementem melhor a analise.

[ ]:
```
# lista de variáveis que quero analisar
vars_to_plot = ["No_of_Votes", "Gross", "Budget_USD", "Profit"]

# loop para cada variável
for col in vars_to_plot:
    # criar versão log
    tabela[col + "_log"] = np.log1p(tabela[col].fillna(0))  # log(1+x) evita␣
 ↪log(0)

    # calcular médias por ano
    normal_mean = tabela.groupby("Released_Year")[col].mean()
    log_mean    = tabela.groupby("Released_Year")[col + "_log"].mean()

    # plotar
    plt.figure(figsize=(10,5))
    plt.plot(normal_mean.index, normal_mean.values, label=f"{col} (normal)",␣
 ↪linewidth=2)
    plt.plot(log_mean.index, log_mean.values, label=f"{col} (log)",␣
 ↪linewidth=2, linestyle="dashed")
    plt.title(f"Evolução de {col} - normal vs log", fontsize=14)
    plt.xlabel("Ano de lançamento")
    plt.ylabel("Média por ano")
    plt.legend()
    plt.grid(True, linestyle="--", alpha=0.5)
    plt.show()
```

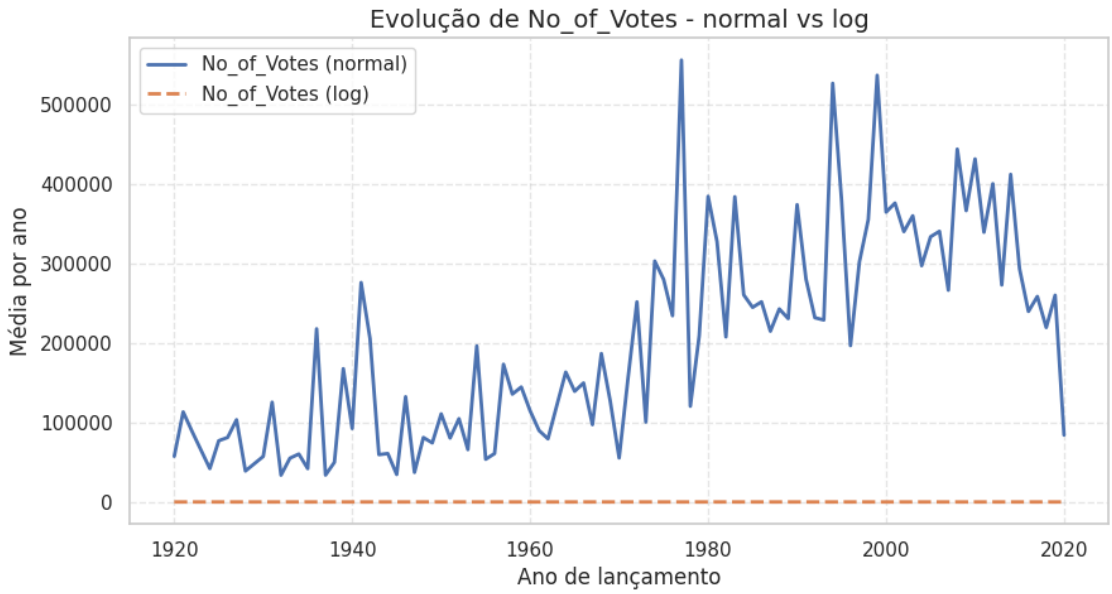

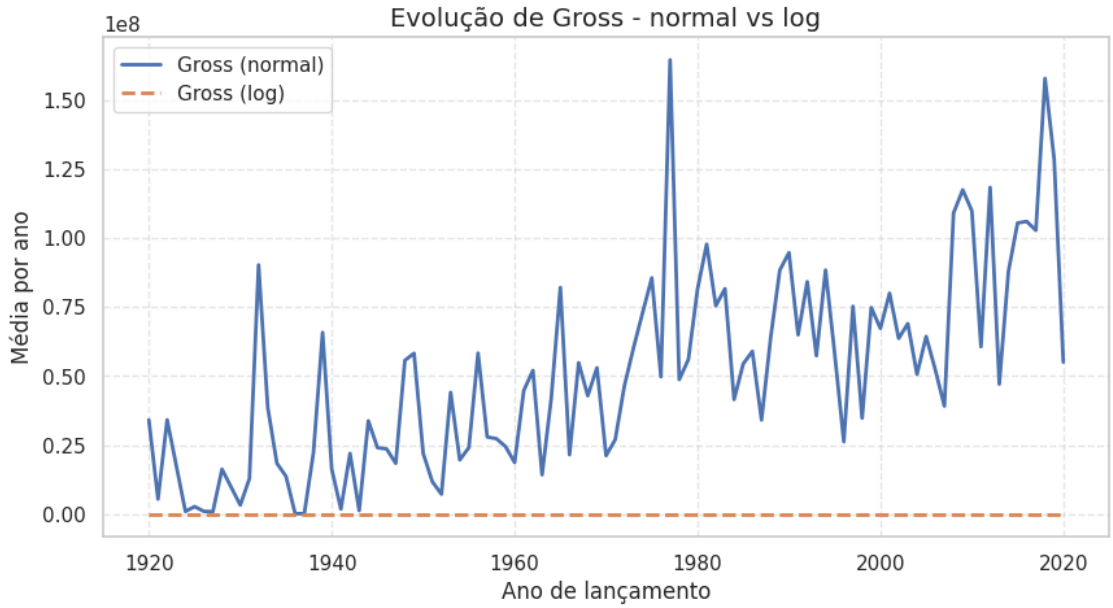

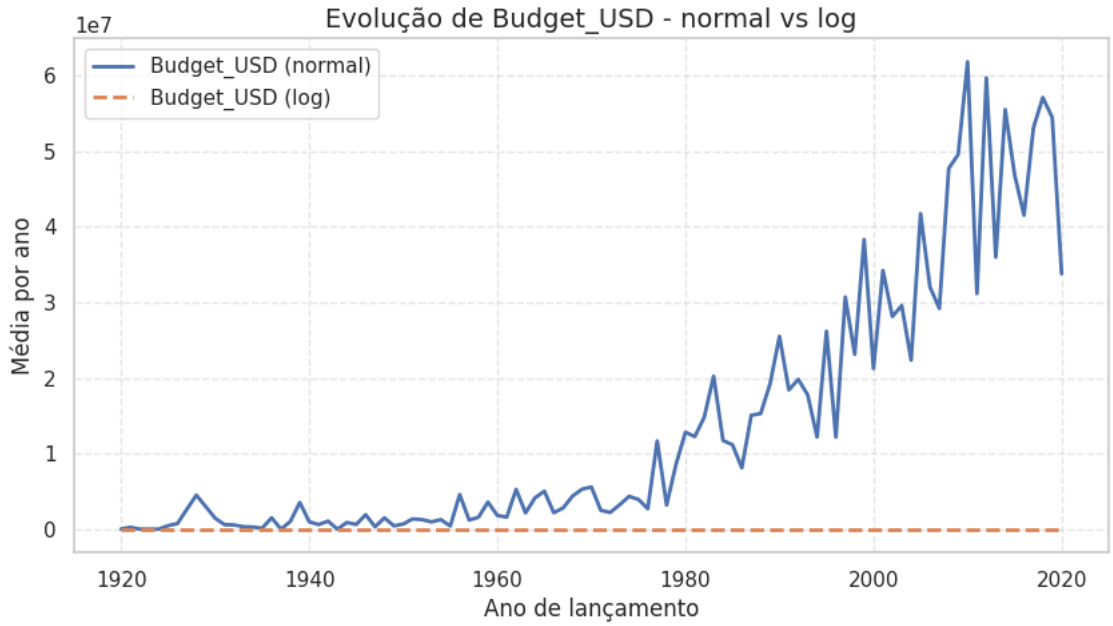


```
/home/lok/.local/lib/python3.10/site-packages/pandas/core/arraylike.py:396:
RuntimeWarning: invalid value encountered in log1p
  result = getattr(ufunc, method)(*inputs, **kwargs)
```

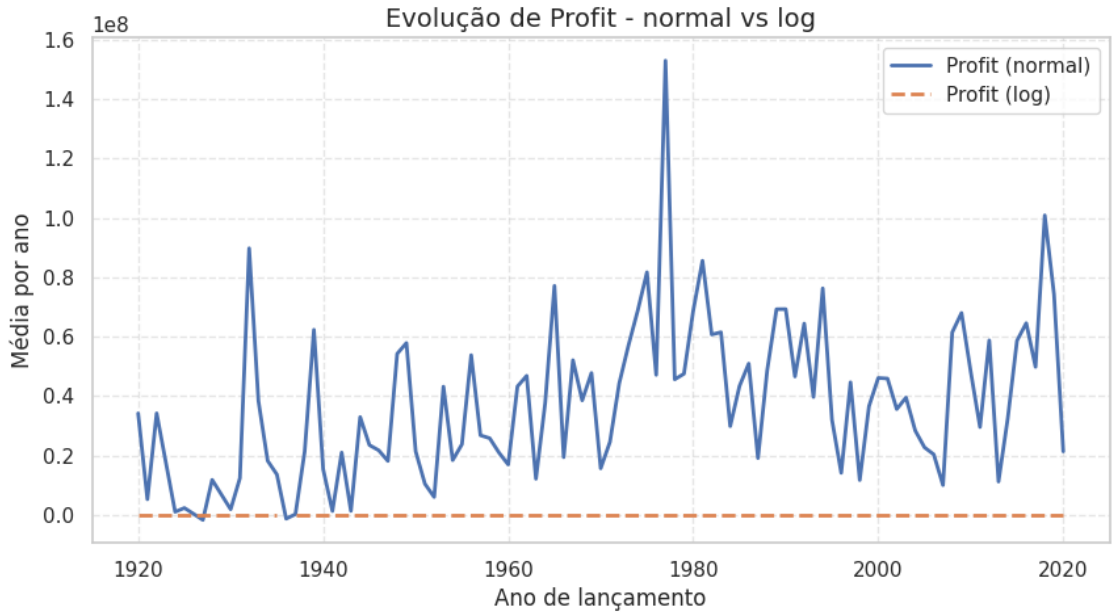

[ ]:
```
# indicadores
tabela['missing_meta'] = tabela['Meta_score'].isna().astype(int)

# usar ano numérico
tabela['Year'] = tabela['Released_Year'].dt.year
tabela['pre1990']       = (tabela['Year'] < 1990).astype(int)
tabela['year_centered'] = (tabela['Year'] - 1990).fillna(0)

# listas de colunas de dummies
genero_cols = generos_dummies.columns.tolist() if 'generos_dummies' in␣
 ↪globals() else [c for c in tabela.columns if tabela[c].dropna().isin([0,1]).
 ↪all() and not c.startswith('lang_')]
idioma_cols = idiomas_dummies.columns.tolist() if 'idiomas_dummies' in␣
 ↪globals() else [c for c in tabela.columns if c.startswith('lang_')]

# base numérica principal (consistente com nomes usados nas interações)
base_num = pd.DataFrame({
    "Meta_score":    pd.to_numeric(tabela["Meta_score"], errors="coerce"),
    "No_of_Votes":   pd.to_numeric(tabela["No_of_Votes"], errors="coerce"),
    "Runtime":       pd.to_numeric(tabela["Runtime"], errors="coerce"),
    "Budget_USD":    pd.to_numeric(tabela["Budget_USD"], errors="coerce"),
    "Gross":         pd.to_numeric(tabela["Gross"], errors="coerce"),
    "Year":          pd.to_numeric(tabela["Year"], errors="coerce"),
    "year_centered": pd.to_numeric(tabela["year_centered"], errors="coerce"),
    "pre1990":       tabela["pre1990"].astype(int),
    "missing_meta":  tabela["missing_meta"].astype(int),
```

```
})

# interações com era
for c in␣
 ↪["Meta_score","No_of_Votes","Runtime","Budget_USD","Gross","missing_meta"]:
    base_num[f"{c}_x_pre1990"] = base_num[c] * base_num["pre1990"]

# X e y
X = pd.concat(
    [base_num,
     tabela[genero_cols].fillna(0).astype(int),
     tabela[idioma_cols].fillna(0).astype(int)],
    axis=1
).fillna(0)

y = pd.to_numeric(tabela["IMDB_Rating"], errors="coerce")

# remover linhas sem alvo/ano (corrige o typo e usa 'Year')
mask = (~y.isna()) & (~X['Year'].isna())
X, y = X.loc[mask], y.loc[mask]

# estratificação por faixas de ano (usa ano numérico)
bins = pd.cut(X['Year'], [1900,1990,2000,2010,2020,2035], right=False,␣
 ↪labels=False, include_lowest=True)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,␣
 ↪random_state=42, stratify=bins)

# métricas auxiliares
def eval_and_print(name, y_true, y_pred, X_eval):
    r2   = r2_score(y_true, y_pred)
    rmse = np.sqrt(mean_squared_error(y_true, y_pred))
    mae  = mean_absolute_error(y_true, y_pred)
    pre_mask  = X_eval["pre1990"]==1
    post_mask = X_eval["pre1990"]==0
    r2_pre  = r2_score(y_true[pre_mask],  y_pred[pre_mask])  if pre_mask.
 ↪sum()>=5 else np.nan
    r2_post = r2_score(y_true[post_mask], y_pred[post_mask]) if post_mask.
 ↪sum()>=5 else np.nan
    print(f"\n{name}\nR²  = {r2:.4f}\nRMSE= {rmse:.4f}\nMAE = {mae:.4f}\nR²␣
 ↪<1990 = {r2_pre:.4f} | R²  1990 = {r2_post:.4f}")

def era_weights(pre1990_series):
    n = len(pre1990_series)
    n_pre  = int((pre1990_series==1).sum())
    n_post = n - n_pre
    return np.where(pre1990_series==1, n/(2*max(n_pre,1)), n/(2*max(n_post,1)))
```

```
w_train = era_weights(X_train['pre1990'].values)

# Random Forest - sem pesos
rf = RandomForestRegressor(random_state=42, n_estimators=300, max_depth=15,␣
 ↪min_samples_leaf=2, n_jobs=-1)
rf.fit(X_train, y_train)
pred_rf = rf.predict(X_test)
eval_and_print("RandomForest (sem pesos)", y_test, pred_rf, X_test)

# Random Forest - com pesos
rf_w = RandomForestRegressor(random_state=42, n_estimators=300, max_depth=15,␣
 ↪min_samples_leaf=2, n_jobs=-1)
rf_w.fit(X_train, y_train, sample_weight=w_train)
pred_rf_w = rf_w.predict(X_test)
eval_and_print("RandomForest (com pesos por era)", y_test, pred_rf_w, X_test)

# Regressão Linear - sem pesos
lin = LinearRegression()
lin.fit(X_train, y_train)
pred_lin = lin.predict(X_test)
eval_and_print("Linear (sem pesos)", y_test, pred_lin, X_test)

# Regressão Linear - com pesos
lin_w = LinearRegression()
lin_w.fit(X_train, y_train, sample_weight=w_train)
pred_lin_w = lin_w.predict(X_test)
eval_and_print("Linear (com pesos por era)", y_test, pred_lin_w, X_test)

# coeficientes da Regressão Linear (Top 15 por |coef|)
coef = (pd.DataFrame({"Variavel": X.columns, "Coeficiente": lin.coef_})
          .assign(abs_coef=lambda d: d["Coeficiente"].abs())
          .sort_values("abs_coef", ascending=False))
print("\nCoeficientes (Linear) - Top 15 por |coef|:")
print(coef.head(15)[["Variavel","Coeficiente"]].to_string(index=False))
```

```
RandomForest (sem pesos)
R²  = 0.4744
RMSE= 0.1836
MAE = 0.1509
R² <1990 = 0.5703 | R²  1990 = 0.3951

RandomForest (com pesos por era)
R²  = 0.4764
RMSE= 0.1832
MAE = 0.1500
```

```
R² <1990 = 0.5727 | R²  1990 = 0.3967

Linear (sem pesos)
R²  = 0.4217
RMSE= 0.1926
MAE = 0.1447
R² <1990 = 0.6355 | R²  1990 = 0.2651

Linear (com pesos por era)
R²  = 0.4200
RMSE= 0.1929
MAE = 0.1447
R² <1990 = 0.6393 | R²  1990 = 0.2598

Coeficientes (Linear) - Top 15 por |coef|:
Variavel  Coeficiente
 lang_nl    -0.526032
 lang_en    -0.515780
 lang_es    -0.431979
 lang_uz    -0.426199
 lang_ga    -0.414446
 lang_fr    -0.395410
 lang_bs    -0.377880
 lang_ro    -0.372714
 lang_ru    -0.362350
 lang_da    -0.360935
 lang_zh    -0.359995
 lang_ta     0.359330
 lang_de    -0.357196
 lang_it    -0.356076
 lang_sv    -0.350564
```

[ ]:
```python
def era_weights(pre1990_series):
    n = len(pre1990_series)
    n_pre  = int((pre1990_series==1).sum())
    n_post = n - n_pre
    return np.where(pre1990_series==1, n/(2*max(n_pre,1)), n/(2*max(n_post,1)))

def eval_metrics(y_true, y_pred, X_eval_df):
    r2   = r2_score(y_true, y_pred)
    rmse = np.sqrt(mean_squared_error(y_true, y_pred))
    mae  = mean_absolute_error(y_true, y_pred)
    pre_mask  = X_eval_df["pre1990"]==1
    post_mask = ~pre_mask
    r2_pre  = r2_score(y_true[pre_mask],  y_pred[pre_mask])  if pre_mask.
 ↪sum()>=5 else np.nan
```

```
    r2_post = r2_score(y_true[post_mask], y_pred[post_mask]) if post_mask.
 ↪sum()>=5 else np.nan
    return r2, rmse, mae, r2_pre, r2_post

# garantir que as interações existam
for c in␣
 ↪["Meta_score","No_of_Votes","Runtime","Budget_USD","Gross","missing_meta"]:
    col_int = f"{c}_x_pre1990"
    if col_int not in base_num.columns:
        base_num[col_int] = base_num[c] * base_num["pre1990"]

y = pd.to_numeric(tabela["IMDB_Rating"], errors="coerce")

# listas de colunas de dummies
genero_cols = generos_dummies.columns.tolist() if 'generos_dummies' in␣
 ↪globals() else [c for c in tabela.columns if tabela[c].dropna().isin([0,1]).
 ↪all() and not c.startswith('lang_')]
idioma_cols = idiomas_dummies.columns.tolist() if 'idiomas_dummies' in␣
 ↪globals() else [c for c in tabela.columns if c.startswith('lang_')]

# monta design
def make_design(use_text: bool, svd_components: int = 100, min_df: int = 3,␣
 ↪ngram=(1,2)):
    X_struct = pd.concat(
        [base_num,
         tabela[genero_cols].fillna(0).astype(int) if genero_cols else pd.
 ↪DataFrame(index=tabela.index),
         tabela[idioma_cols].fillna(0).astype(int)  if idioma_cols else pd.
 ↪DataFrame(index=tabela.index)],
        axis=1
    ).fillna(0)

    # ano numérico
    year_num = tabela.loc[X_struct.index, "Year"]

    # filtro
    mask = (~y.loc[X_struct.index].isna()) & (~year_num.isna())
    X_struct = X_struct.loc[mask]
    y_ok     = y.loc[mask]
    year_ok  = year_num.loc[mask]

    # estratificação por faixas de ano
    bins = pd.cut(year_ok, [1900,1990,2000,2010,2020,2035], right=False,␣
 ↪labels=False, include_lowest=True)
    X_tr, X_te, y_tr, y_te = train_test_split(X_struct, y_ok, test_size=0.2,␣
 ↪random_state=42, stratify=bins)
```

```
    if use_text:
        kw_tr = tabela.loc[X_tr.index, 'Keywords'].fillna('').astype(str)
        kw_te = tabela.loc[X_te.index, 'Keywords'].fillna('').astype(str)

        tfidf = TfidfVectorizer(lowercase=True, strip_accents='unicode',␣
 ↪ngram_range=ngram, min_df=min_df, max_features=5000)
        X_kw_tr = tfidf.fit_transform(kw_tr)
        X_kw_te = tfidf.transform(kw_te)

        svd = TruncatedSVD(n_components=svd_components, random_state=42)
        X_kw_tr_svd = svd.fit_transform(X_kw_tr)
        X_kw_te_svd = svd.transform(X_kw_te)

        X_tr_mat = np.hstack([X_tr.values, X_kw_tr_svd])
        X_te_mat = np.hstack([X_te.values, X_kw_te_svd])
        feat_names = X_tr.columns.tolist() + [f"kw_svd_{i+1}" for i in␣
 ↪range(svd_components)]
        return X_tr, X_te, y_tr, y_te, X_tr_mat, X_te_mat, feat_names

    return X_tr, X_te, y_tr, y_te, X_tr.values, X_te.values, X_tr.columns.
 ↪tolist()

# roda RF e métricas
def run_rf(X_tr_df, X_te_df, y_tr, y_te, X_tr_mat, X_te_mat, feat_names,␣
 ↪use_weights: bool, rf_params=None):
    if rf_params is None:
        rf_params = dict(random_state=42, n_estimators=300, max_depth=15,␣
 ↪min_samples_leaf=2, n_jobs=-1)
    rf = RandomForestRegressor(**rf_params)
    if use_weights:
        w = era_weights(X_tr_df['pre1990'].values)
        rf.fit(X_tr_mat, y_tr, sample_weight=w)
    else:
        rf.fit(X_tr_mat, y_tr)
    pred = rf.predict(X_te_mat)
    r2, rmse, mae, r2_pre, r2_post = eval_metrics(y_te, pred, X_te_df)
    imp = pd.DataFrame({'feature': feat_names, 'importance': rf.
 ↪feature_importances_}).sort_values('importance', ascending=False)
    return (r2, rmse, mae, r2_pre, r2_post), imp

# experimentos
experimentos = []

# baseline: sem texto
Xtr, Xte, ytr, yte, Xtrm, Xtem, names = make_design(use_text=False)
```

```
for use_w in [False, True]:
    m, imp = run_rf(Xtr, Xte, ytr, yte, Xtrm, Xtem, names, use_weights=use_w)
    experimentos.append(dict(setup=f"NoText | weights={use_w}", R2=m[0],␣
 ↪RMSE=m[1], MAE=m[2], R2_pre=m[3], R2_pos=m[4]))

# com texto: testar SVD=50 e 100, min_df=5
for svd_k in [50, 100]:
    Xtr, Xte, ytr, yte, Xtrm, Xtem, names = make_design(use_text=True,␣
 ↪svd_components=svd_k, min_df=5, ngram=(1,2))
    for use_w in [False, True]:
        params = dict(random_state=42, n_estimators=500, max_depth=12,␣
 ↪min_samples_leaf=3, max_features='sqrt', n_jobs=-1)
        m, imp = run_rf(Xtr, Xte, ytr, yte, Xtrm, Xtem, names,␣
 ↪use_weights=use_w, rf_params=params)
        experimentos.append(dict(setup=f"Text(svd={svd_k},min_df=5) |␣
 ↪weights={use_w}", R2=m[0], RMSE=m[1], MAE=m[2], R2_pre=m[3], R2_pos=m[4]))

# resultado
res = pd.DataFrame(experimentos).sort_values('R2', ascending=False)
print(res.to_string(index=False))
```

```
                              setup       R2     RMSE      MAE   R2_pre
R2_pos
                NoText | weights=True 0.476366 0.183250 0.149963 0.572711
0.396703
               NoText | weights=False 0.474444 0.183586 0.150887 0.570252
0.395058
 Text(svd=50,min_df=5) | weights=False 0.340902 0.205591 0.167224 0.389035
0.287369
  Text(svd=50,min_df=5) | weights=True 0.339857 0.205754 0.167331 0.396224
0.281025
 Text(svd=100,min_df=5) | weights=True 0.302300 0.211526 0.171520 0.359816
0.241436
Text(svd=100,min_df=5) | weights=False 0.300888 0.211740 0.171557 0.343239
0.249667
```

weights=True é quando está aplicado os pesos, false é sem.